Univerzitet u Novom Sadu

Tehnički fakultet „Mihajlo Pupin“

Zrenjanin

Komparativna analiza arhitektura neuronskih mreža pri klasifikaciji fotografija galaksija

Comparative Analysis of Neural Network Architectures for Galaxy Image Classification

- Master rad -

Mentor: Doc. dr Višnja Ognjenović

Student: Aleksandar Konstantin

Broj indeksa: MIT 5/25

Smer: Informacione tehnologije

Zrenjanin, 2026. godina

Univerzitet u Novom Sadu

Tehnički fakultet „Mihajlo Pupin“

Zrenjanin

Ključna dokmentacijska informacija

Redni broj: RBR	
Identifikacioni broj: IBR	MIT 5/25
Tip dokumentacije: TD	Monografska dokumentacija
Tip zapisa: TZ	Tekstualni štampani materijal
Vrsta rada: VR	Master rad
Ime i prezime autora: AU	Aleksandar Konstantin
Mentor: MN	Doc. dr Višnja Ognjenović
Naslov rada: NR	Komparativna analiza arhitektura neuronskih mreža pri klasifikaciji fotografija galaksija
Jezik publikacije: JP	srpski
Jezik izvoda: JI	srpski/engleski
Zemlja publikovanja: ZP	Republika Srbija
Uže geografsko područje: UGP	AP Vojvodina
Godina: GO	2026.
Izdavač: IZ	autorski reprint
Mesto i adresa: MA	Tehnički fakultet „Mihajlo Pupin“, Zrenjanin, Đure Đakovića BB
Fizički opis rada: FO	7/55/21/0/31/0 (broj poglavlja/stranica/slika/grafikona/referenci/priloga)
Naučna oblast: NO	Informacione tehnologije
Naučna disciplina: ND	Mašinsko učenje
Predmetna odrednica, ključne reči:	Klasifikacija galaksija primenom dubokog učenja,

PO	veštačka inteligencija, mašinsko učenje, duboko učenje, CNN, ResNet18, EfficientNetB0, Galaxy Zoo 2
UDK	
Čuva se: ČU	U biblioteci Tehničkog fakulteta „Mihajlo Pupin“, u Zrenjaninu
Važna napomena: VN	Nema
Izvod: IZ	Osnovna ideja rada jeste komparativna analiza arhitektura neuronskih mreža pri klasifikaciji fotografija galaksija
Datum prihvatanja teme od strane NN veća: DP	
Datum odbrane: DO	
Članovi komisije: KO	predsednik: Prof. dr Vladimir Brtka član: Prof. dr Darko Radovančević član, mentor: Doc. dr Višnja Ognjenović

University of Novi Sad

Technical Faculty „Mihajlo Pupin“ Zrenjanin

Key word documentation

Accession number: ANO	
Identification number: INO	MIT 5/25
Document Type: DT	Monograph documentation
Type of record: TR	Textual printed material
Concents code: CC	Master thesis
Author: AU	Aleksandar Konstantin
Menthor: MN	Višnja Ognjenović, PhD
Title: TI	Comparative Analysis of Neural Network Architectures for Galaxy Image Classification
Language of text: LT	Serbian
Language of abstract: LA	Serbian/English
Country of publication: CP	Republic of Serbia
Locality of publication: LP	Autonomous Province
Publication year: PY	2026.
Publisher: PU	Author’s reprint
Publication place: PP	Technical faculty „Mihajlo Pupin“, Zrenjanin, Djure Djakovica BB
Physical description: PD	
Scientific field: SF	Information technologies
Scientific discipline: SD	Machine learning
Subject, Key words: SKW	Classification of galaxies using deep learning, artificial intelligence, machine learning, deep learning, CNN, ResNet18, EfficientNetB0, Galaxy

	Zoo 2
UC	
Holding data: HD	The library of Technical faculty „Mihajlo Pupin, Zrenjanin
Note: N	Not included
Abstract: AB	The basic idea of this thesis is comparative analysis of neural network architectures for galaxy image classification
Acccepted on Scientific Board on: AS	
Defended: DE	
Thesis Defend Board: DR	president: phD Vladimir Brtka member: phD Darko Radovancevic member, menthor: phD Visnja Ognjenovic

SADRŽAJ

1 Uvod 6
2 Teorijsko istraživanje 8
2.1 Veštačka inteligencija 8
2.2 Mašinsko učenje 10
2.2.1 Način rada mašinskog učenja 10
2.2.2 Tipovi mašinskog učenja 11
2.3 Duboko učenje 12
2.4 Neuronske mreže 13
2.4.1 Aktivacione funkcije 15
2.4.2 Konvolucione neuronske mreže (CNN) 22
2.4.3 ResNet18 24
2.4.4 EfficientNetB0 25
2.5 Evalucione metrike 26
2.5.1 Metrike za klasifikaciju 26
2.6 Morfološka klasifikacija galaksija 28
2.7 Galaxy Zoo 2 29
2.7.1 Oznake (labele) u Galaxy Zoo 2 30
2.8 Binarna klasifikacija 30
3 Metodološki okvir istraživanja 32
3.1 Problem istraživanja 32
3.2 Predmet istraživanja 32
3.3 Cilj istraživanja 32
3.4 Zadaci istraživanja 32
3.5 Hipoteza istraživanja 33
3.6 Metod istraživanja 33
3.7 Instrumenti istraživanja 33
3.7.1 Visual Studio Code 33
3.7.2 Galaxy Zoo 2 podaci 34
4 Eksperimentalno istraživanje 35
4.1 Opis istraživanja 35
4.2 Implementacije eksperimentalnog sistema 36
4.2.1 Priprema skupa podataka 37
4.2.2 Uzorkovanje i podela podataka 37
4.2.3 Obrada slika 38

4.2.4 Implementacija modela dubokog učenja 38
4.2.5 Proces treniranja modela 39
4.2.6 Evaluacija modela 39
4.2.7 Organizacija izlaznih rezultata 40
4.3 Analiza rezultata 40
4.3.1 Rezultati evaluacije modela 40
4.3.2 Matrice konfuzije 42
4.3.3 Uporedna analiza 43
4.3.4 Analiza pojedinačnih predikcija 44
4.3.5 Diskusija rezultata 45
5 Ključni delovi koda 46
5.1 Priprema skupa podataka 46
5.2 Kreiranje TensorFlow skupa podataka 46
5.3 Implementacija modela dubokog učenja 48
5.3.1 Konvoluciona neuronska mreža (CNN) 48
5.3.2 ResNet18 49
5.3.3 EfficientNetB0 51
5.4 Proces treniranja modela 51
5.5 Evaluacija modela 52
6 Zaključak 53
7 Literatura i ilustracije 54

1 UVOD

U savremenoj eri veštačke inteligencije i obrade podataka, mašinsko učenje predstavlja jedan od ključnih alata za analizu velikih i kompleksnih skupova podataka. Njegova primena posebno dolazi do izražaja u oblastima gde je potrebno prepoznavanje obrazaca i klasifikacija vizuelnih informacija, kao što je to slučaj u astronomiji i obradi astronomskih slika.

Automatska klasifikacija galaksija predstavlja značajan izazov u oblasti računske astronomije, s obzirom na veliku raznovrsnost njihovih morfoloških oblika i ogromnu količinu dostupnih podataka. Tradicionalne metode ručne klasifikacije, poput vizuelne analize od strane astronoma ili volontera, nisu skalabilne u kontekstu modernih astronomskih istraživanja koja generišu milione slika nebeskih objekata.

Razvoj dubokog učenja, posebno konvolucionih neuronskih mreža (CNN), omogućio je značajan napredak u automatskoj analizi i klasifikaciji astronomskih slika. Ovi modeli su sposobni da iz sirovih podataka izdvoje relevantne karakteristike i nauče kompleksne reprezentacije koje omogućavaju visoku tačnost u prepoznavanju različitih tipova galaksija.

U ovom radu fokus je na primeni i poređenju različitih arhitektura dubokog učenja u zadatku binarne klasifikacije galaksija na eliptične (E) i spiralne (S) forme. Posebna pažnja posvećena je analizi performansi modela CNN, ResNet18 i EfficientNetB0, kao i evaluaciji njihovih rezultata pomoću standardnih metrika mašinskog učenja.

Cilj istraživanja je da se ispita efikasnost različitih modela dubokog učenja u zadatku klasifikacije galaksija, kao i da se identifikuje arhitektura koja daje najbolje rezultate u smislu tačnosti i generalizacije na nepoznatim podacima.

Rad je strukturiran na način da vodi čitaoca od opštih pojmova ka specifičnim i time povezuje teorijski okvir sa eksperimentalnim istraživanjem:

- Poglavlje 1 – Uvod:
  U uvodu se daje pregled primene mašinskog i dubokog učenja u astronomiji, sa fokusom na problem automatske klasifikacije galaksija. Ističe se značaj CNN modela i savremenih arhitektura u analizi astronomskih slika i definisanju cilja rada – poređenje njihovih performansi u zadatku binarne klasifikacije galaksija.

- Poglavlje 2 – Teorijsko istraživanje:
  Obuhvata teorijske osnove veštačke inteligencije, mašinskog i dubokog učenja, neuronskih i konvolucionih neuronskih mreža, kao i pregled arhitektura CNN, ResNet18 i EfficientNetB0. Takođe razmatra evaluacione metrike za procenu performansi modela, principe morfološke klasifikacije galaksija, karakteristike skupa podataka Galaxy Zoo 2 i koncept binarne klasifikacije, koji predstavljaju teorijsku osnovu za sprovođenje eksperimentalnog dela istraživanja.

- Poglavlje 3 – Metodološki okvir istraživanja:
  Sadrži problem i predmet istraživanja, kao i cilj i zadatke istraživanja, hipotezu i instrumente istraživanja.

- Poglavlje 4 – Eksperimentalno istraživanje:

Eksperimentalno istraživanje obuhvata implementaciju ML pipeline-a za klasifikaciju galaksija korišćenjem CNN, ResNet18 i EfficientNetB0 modela. Njegov cilj je poređenje performansi različitih arhitektura na zadatku binarne klasifikacije eliptičnih i spiralnih galaksija.

- Poglavlje 5 – Ključni delovi koda:
  Ovo poglavlje sadrži ključne delove sa objašnjenjima istih.

- Poglavlje 6 – Zaključak:

  Sumira ciljeve i glavne nalaze rada, diskutuje o implikacijama istraživanja i daje preporuke za budući razvoj istraživanja u ovoj oblasti.

- Poglavlje 7 - Literatura: Sadrži popis svih korišćenih izvora i relevantnih radova u skladu sa odabranim citatnim standardom.

2 TEORIJSKO ISTRAŽIVANJE

U okviru teorijskog istraživanja izvršena je analiza relevantne literature iz oblasti veštačke inteligencije, mašinskog i dubokog učenja, sa posebnim osvrtom na konvolucione neuronske mreže i arhitekture ResNet18 i EfficientNetB0. Takođe su obrađeni osnovni pojmovi iz oblasti astronomije i morfološke klasifikacije galaksija, kao i karakteristike skupa podataka Galaxy Zoo 2 i evaluacionih metrika primenjenih u eksperimentalnom delu istraživanja.

2.1 POJAM VEŠTAČKE INTELIGENCIJE

Veštačka inteligencija (eng. Artificial Intelligence - AI) je tehnologija koja omogućava računarima i mašinama da simuliraju ljudsko učenje, razumevanje, rešavanje problema, donošenje odluka, kreativnost i autonomiju [1].

2.1.1 GRANE VEŠTAČKE INTELIGENCIJE

Veštačka inteligencija ili AI, obuhvata brojne grane pri čemu svaka grana koristi različite metode kako bi mašine oponašale ljudsku inteligenciju [2].

U najrasprostranjenije grane veštačke inteligencije ubrajaju se [2]:

1. Mašinsko učenje (eng. Machine Learning - ML):

   Mašinsko učenje obuhvata korišćenje algoritama koji omogućavaju sistemima da uče i prave procene na osnovu podataka.
   S obzirom da se ovo istraživanje zasniva na primeni mašinskog učenja, ova oblast će biti detaljnije obrađena u narednom poglavlju.

2. Obrada prirodnog jezika (eng. Natural Language Processing - NLP):

   Obrada prirodnog jezika (NLP) fokusira se na interakciju između računara i ljudskih jezika, omogućavajući mašinama da razumeju, interpretiraju i generišu ljudski jezik.
   Obrada prirodnog jezika pronalazi primenu kod prevođenja jezika, analize sentimenta[1], chatbot-ova[2], sažimanja teksta,...

3. Računarski vid (eng. Computer Vision – CV):

   Računarski vid omogućuje mašinama da tumače i donose odluke na osnovu vizuelnih podataka.
   Računarski vid se primenjuje u oblasti prepoznavanja lica, oblasti autonomih vozila, analizi medicinskih snimaka kao i za nadzor i kod raznih drugih oblasti.

4. Robotika (eng. Robotics):

[1] Analiza sentimenata - analiza sentimenata je tehnika NLP-a koja koristi računarsku lingvistiku i mašinsko učenje kako bi otkrila emocionalni ton iza tekstualnih podataka i time identifikovala da li je ton pozitivan, neutralan ili negativan [3].
[2] Chatbot - Chatbot je kompjuterski program osmišljen da simulira razgovor sa ljudima, obično kroz tekstualne ili glasovne interakcije [4].

Robotika je grana veštačke inteligencija koja se bavi dizajniranjem, konstrukcijom, radom i primenom robota.
Primeri primene robotike jesu automatizacija u proizvodnji, medicinski roboti, roboti za istraživanje svemira ili podvodni roboti, kao i mnogi drugi.

5. Ekspertni sistemi (eng. Expert Systems):

   Ekspertni sistemi su AI programi koji simuliraju sposobnost donošenja odluka kakvu imaju ljudski stručnjaci.
   Primena ovih sistema jeste u medicinskoj dijagnostici, predviđanju finansija, sistemima za otklanjanje kvarova i drugim.

6. Duboko učenje (eng. Deep Learning):

   Neuronske mreže su računarski sistemi inspirisani biološkim neuronskim mrežama u mozgu životinja, dok je duboko učenje podskup mašinskog učenja koji koristi neuronske mreže sa više slojeva.
   Primeri primene dubokog učenja jesu prepoznavanje govora, obrada prirodnog jezika, igranja igara, prepoznavanje slika u raznim oblastima.

   Arhitekture korišćene u ovom istraživanju zasnovane su na dubokom učenju, zbog čega će duboko učenje biti detaljnije predstavljeno u posebnom poglavlju.

7. Fazi logika (eng. Fuzzy logic):

   Fazi logika je oblik viševrednosne logike koja se bavi rasuđivanjem koje je približno, a ne zasnovano na tačnim (preciznim) i fiksnim pravilima i vrednostima.
   Primeri primene fazi logike jesu sistemi za donošenje odluka, prepoznavanje obrazaca, sistemi upravljanja i drugi.

8. Evolutivna računarska obrada (eng. Evolution Computation):

   Evolutivna računarska obrada je porodica algoritama za globalnu optimizaciju inspirisana biološkom evolucijom.
   Primeri primene evolutivne računarske obrade jesu veštački život, evolutivna robotika, problemi optimizacije i drugi.

9. Inteligencija kolektiva (eng. Swarm intelligence):

   Inteligencija kolektiva podrazumeva kolektivno ponašanje decentralizovanih, samostalno organizovanih sistema, obično sastavljenih od populacije jednostavnih agenata[3]. Primeri primene inteligencije kolektiva jesu rutiranje u mrežama, robotika, problemi optimizacije i mnogi drugi.

10. Kognitivno računarstvo (eng. Cognitive Computing):

[3] Agent - AI agenti su softverski entiteti kojima se mogu dodeljivati zadaci, koji mogu da posmatraju i analiziraju svoje okruženje, preduzimaju akcije u skladu sa svojom ulogom i prilagođavaju se na osnovu prethodnih iskustava [5].

Kognitivno računarstvo odnosi se na sisteme koji oponašaju procese ljudskog razmišljanja u računarskom modelu. Primeri primene jesu korisnička podrška, dijagnostika u medicini, analiza finansija i drugo.

2.2 MAŠINSKO UČENJE

Mašinsko učenje (eng. Machine Learning - ML) je podskup veštačke inteligencije koji se bavi izgradnjom sistema koji uče i unapređuju se tako što obrađuju sve veće i veće količine podataka [6].

Mašinsko učenje je tehnika koja otkriva prethodno nepoznate veze u podacima tako što pretražuje potencijalno veoma velike skupove podataka u svrhu pronalaženja obrazaca i trendova koji prevazilaze jednostavnu statističku analizu [6].

Mašinsko učenje koristi sofisticirane algoritme koji se treniraju da identifikuju obrasce koji su skriveni u podacima, time kreirajući modele. Ovi modeli se koriste za pravljenje predikcija i kategorizaciju, odnosno klasifikaciju podataka [6].

2.2.1 FAZE RADA MAŠINSKOG UČENJA

Prvi korak u mašinskom učenju je prikupljanje relevantnih podataka, koji mogu poticati iz izvora kao što su baze podataka, senzori ili internet [7].

Faze, odnosno koraci ka kreiranju modela mašinskog učenja su sledeći [7]:

[1] Preprocesiranje podataka (eng. preprocessing data):

Nakon što se podaci prikupe, potrebno ih je obraditi (preprocesirati) kako bi se obezbedio kvalitet i pogodnost za analizu.

[2] Treniranje modela (eng. training):

Nakon što su podaci obrađeni sledi obuka mašinskog modela, odnosno algoritma ili matematičke reprezentacije koja uči da pravi predikcije ili odluke na osnovu ulaznih podataka.

[3] Odabir i inženjering karakteristika (eng. feature selection and engineering):

Model zatim bira najrelevantnije karakteristike iz ulaznih podataka koje će značajno uticati na performanse modela.

[4] Evaluacija i optimizacija modela (eng. evaluating and optimizing the model):

Kada se model obuči, potrebno ga je oceniti, odnosno evaluirati kako bi se procenile njegove performanse i utvrdilo da li ispunjava željene kriterijume.

[5] Primena i nadgledanje (eng. deployment and monitoring):

Nakon uspešne obuke i vrednovanja, model se može primeniti u realnim aplikacijama mašinskog učenja.

2.2.2 TIPOVI MAŠINSKOG UČENJA

Postoje četiri glavna tipa mašinskog učenja, pri čemu svaki od njih ima svoje prednosti i ograničenja [6]:

- Nadgledano (eng. Supervised Machine Learning),
- Nenadgledano (eng. Unsupervised Machine Learning),
- Polunadgledano (eng. Semi-supervised Machine Learning),
- Podržano učenje (eng. Reinforcement Learning).

2.2.2.1 NADGLEDANO MAŠINSKO UČENJE

Nadgledano mašinsko učenje je najučestaliji tip mašinskog učenja. Kod ovog tipa za obuku modela se koriste označeni (labeled) podaci, što modelu govori tačno kako da donosi odluke [6].

Ovaj tip mašinskog učenja zahteva da se pothrani korektnim podacima sa oznakama, kako bi algoritam mogao pravilno da uči i daje precizne predikcije u budućnosti [6].

Primer nadgledanog učenja jeste filter za nepoželjnu elektronsku poštu (eng. spam emails), gde algoritam uči iz skupa podataka sa oznakama koje označavaju koji mejl je nepoželjan, a koji ne. Ovakav model ima mogućnost da predvidi da li je neka nova pristižuća pošta nepoželjna ili ne, na osnovu obrazaca koje je identifikovao prilikom treniranja [6].

Cilj ovog tipa učenja nije da koristi savršene podatke. Uzimajući u obzir da podaci u realnom svetu skoro nikada nisu savršeni, cilj jeste imitirati podatke iz realnog sveta. Savršeni, odnosno preterano "čisti" (eng. clean) podaci mogu dovesti do preteranog fitovanja (eng. overfitting), odnosno prilagođavanja što znači da će model funkcionisati isključivo na skupovima podataka koji su preterano čisti [6].

Eksperimentalno istraživanje u okviru ovog rada pripada oblasti nadgledanog mašinskog učenja, jer se modeli obučavaju korišćenjem unapred označenih primera iz Galaxy Zoo 2 skupa podataka.

2.2.2.2 NENADGLEDANO MAŠINSKO UČENJE

Nenadgledano mašinsko učenje koristi nezavisniji pristup u odnosu na nadgledano, gde model samostalno mora da nauči da identifikuje kompleksne obrasce bez oslanjanja na označene podatke. Trening ovih modela koristi podatke bez oznaka i bez definisanog izlaza [6].

Nenadgledano mašinsko učenje uobičajeno grupiše slične podatke, stvarajući klastere (eng. clusters). Nakon treniranja, model je sposoban da detektuje slične obrasce i da prema njima grupiše podatke u odgovarajuće grupe, odnosno klastere [6].

Česta primena nenadgledanog mašinskog učenja jesu algoritmi za preporuke koji se koriste u aplikacijama za krajnje korisnike, odnosno potrošačke aplikacije, kako bi pružili poruke poput "Kupci koji su kupili ovo, često kupe i..." [6].

Još jedan primer nenadgledanog učenja jeste detekcija prevare (eng. fraud detection), jer kada model identifikuje nepoznate obrasce, on ih beleži kao anomalije [6].

2.2.2.3 POLUNADGLEDANO MAŠINSKO UČENJE

Polunadgledano mašinsko učenje rešava problem nedovoljnog broja oznaka u skupu podataka da bi se model obučio putem nadgledanog učenja [6].

Primer slučaja u kom se koristi polunadgledano učenje jeste ako imamo veoma velik skup podataka za treniranje modela, ali nemamo dovoljno vremena ili novca da označimo čitav skup podataka. Kombinovanjem nadgledanog i nenadgledanog učenja često je moguće dobiti u potpunosti treniran model, tako što trening započinje kao nadgledano učenje tako što koristi označene podatke radi dobijanja inicijalnih rezultata i postavljanja smernica za algoritam. Nakon što su iskorišćeni označeni podaci, polutrenirani model prelazi na neoznačene podatke i traži podatke kojima bi mogao sa velikom sigurnošću da dodeli određenu oznaku. Proces treniranja počinje iznova ali sa većim skupom označenih podataka. Iterativnim prolascima, sve više uzoraka se označava sa "pseudo-oznakama" i time se model dodatno poboljšava [6].

2.2.2.4 PODRŽANO UČENJE

Poput nenadgledanog učenja, podržano učenje koristi neoznačene skupove podataka i prepušta algoritmima da sami evaluiraju podatke. Međutim, podržano učenje se razlikuje po tome što ima definisan cilj umesto da "slepo" analizira podatke u nadi da će pronaći obrazac [6].

Sa jasno definisanim ciljem, algoritam započinje proces pokušaja i grešaka. Kroz svaki korak ovog procesa, algoritam dobija pozitivnu, negativnu ili neutralnu povratnu informaciju, na osnovu kojih usavršava svoje donošenje odluka [6].

Iako ovakav tip učenja u početku ima negativne posledice, one su kratkoročne jer algoritmi ovog tipa učenja funkcionišu na makro (eng. macro) nivou ka postizanju svog cilja. Ovaj tip učenja se bolje nosi sa kompleksnim i dinamičkim situacijama nego ostali tipovi učenja, jer ovakav način učenja ima uticaj na "rizike" koraka modela s obzirom da ima unapred određen cilj [6].

Dobar primer podržanog učenja jeste učenje računara da igra šah, gde je glavni cilj modela da pobedi protivnika, a u to ulazi i žrtvovanje figura tokom igre radi postizanja ovog cilja [6].

2.2.3 DUBOKO UČENJE

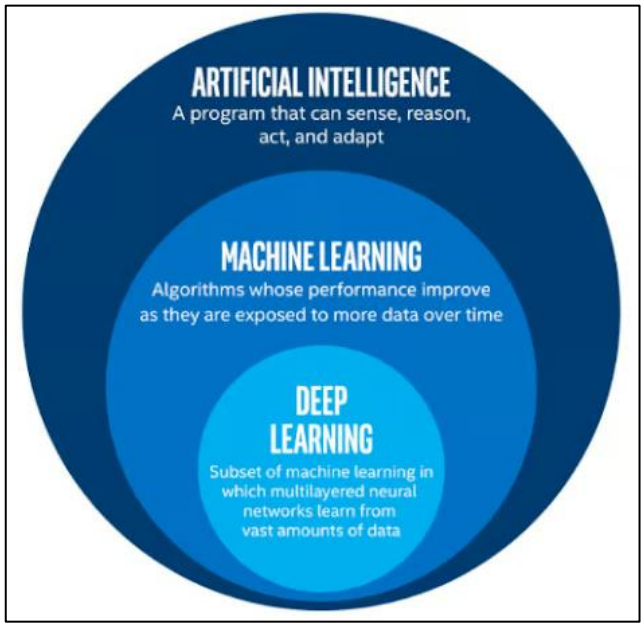
Duboko učenje (eng. Deep Learning) je podskup mašinskog učenja koji se zasniva na neuronskim mrežama[4] sa više slojeva, čiji je dizajn inspirisan strukturom ljudskog mozga. Duboko učeni modeli danas pokreću većinu savremenih (najnaprednijih) oblasti veštačke inteligencije (AI), od računarskog vida i generativne AI do autonomnih vozila i robotike [8].

[4] Neuronske mreže – detaljno objašnjenje se nalazi u narednom poglavlju.

Algoritmi dubokog učenja pokušavaju da donesu slične zaključke kao što bi to činili ljudi, tako što stalno analiziraju podatke uz zadatu logičku strukturu. Da bi to postigli, duboko učenje koristi višeslojnu strukturu algoritama pod nazivom neuronske mreže [9].

Najveća snaga algoritama dubokog učenja je to što mogu da uoče složene obrasce iz sirovih podataka. U kontekstu prepoznavanja slika, to znači da mogu da razlikuju objekte i da prepoznaju složene detalje na slikama i video-zapisima, zahvaljujući tome što uče i jednostavne i složene karakteristike [10].

U oblasti dubokog učenja, gde složeni modeli obrađuju ogromne skupove podataka kako bi izvukli uvide i donosili predikcije, uloga grafičkih procesorskih jedinica (eng. Graphics Processing Units – GPU) je ključna. GPU-i pružaju značajne prednosti u odnosu na centralne procesorske jedinice (Central Processing Units – CPU), posebno u pogledu brzine i efikasnosti pri obuci dubokih neuronskih mreža [11].



Slika 1. – Prikaz ilustracije skupa veštačke inteligencije sa podskupovima.

2.3 NEURONSKE MREŽE

Neuronske mreže predstavljaju modele mašinskog učenja koji se sastoje od više međusobno povezanih slojeva jednostavnih jedinica „neurona[5]“. Tokom procesa obučavanja, parametri modela, kao što su težine[6] i bias[7] vrednosti, se iterativno prilagođavaju kako bi se omogućilo prepoznavanje obrazaca i mapiranje odnosa između ulaznih i izlaznih podataka [12].

[5] Neuron - je osnovna jedinica za obradu informacija u veštačkoj neuronskoj mreži. Neuron se sastoji od pet osnovnih elemenata. U matematičkim modelima neuron se najčešće označava simbolom “k” [13].
[6] Težine (eng. weights) - su numeričke vrednosti koje definišu značaj pojedinačnih ulaza prilikom izračunavanja izlaza neurona. Njihovo podešavanje vrši se tokom treniranja modela sa ciljem poboljšanja njegovih performansi i preciznosti predviđanja [14].
[7] Bias vrednosti (eng. biases) - su parametri koji se dodaju rezultatu zbira ulaznih vrednosti i težina, čime se prilagođava izlaz neurona. Njihova uloga je da unaprede sposobnost modela da uči i prepoznaje obrasce u podacima [14].

Koncept neuronskih mreža inspirisan je funkcionalnošću bioloških neurona u ljudskom mozgu, koji komuniciraju putem električnih signala. Razvoj formalnog modela neurona započeo je sredinom 20. veka radom McCulloch-a i Pitts-a, dok je Rosenblatt kasnije uveo perceptron kao jedan od prvih algoritama za prepoznavanje obrazaca [12].

U svojoj osnovi, neuronske mreže transformišu ulazne podatke kroz više uzastopnih slojeva koji postepeno izdvajaju relevantne karakteristike. Kroz ovaj proces, model koristi težine i bias parametre kako bi odredio značaj pojedinačnih ulaza i prilagodio odluke koje donosi [12].

Na taj način, neuronska mreža aproksimira nelinearnu funkciju koja povezuje ulazne i izlazne vrednosti, omogućavajući efikasno prepoznavanje složenih obrazaca i generisanje predikcija [12].

Neuronsku mrežu čine tri osnovne komponente [12]:

- Ulazni sloj (eng. Input layer):

  Ulazni sloj prima sirove ulazne podatke.

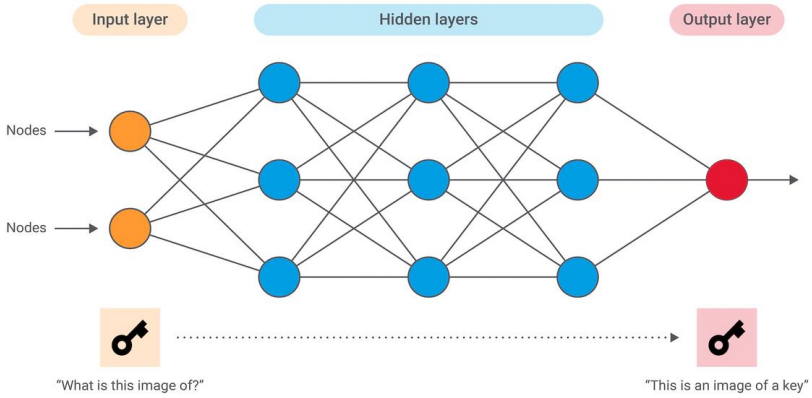
- Skriveni slojevi (eng. Hidden layers)

  Skriveni slojevi se sastoje od veštačkih neurona (ili čvorova) koji transformišu ulazne podatke u nove reprezentacije. Matematički, skriveni slojevi se opisuju kao ulazne karakteristike pomnožene odgovarajućim težinama i uvećane bias vrednostima, pri čemu se tako transformisane vrednosti prosleđuju iz jednog sloja u naredni, sve do izlaznog sloja. U ovoj fazi odvija se linearna transformacija između ulaza i izlaza

- Izlazni slojevi (eng. Output layer):

  Izlazni sloj, nakon primene nelinearne aktivacione funkcije[8] (ReLU, sigmoid ili tanh), generiše konačnu predikciju modela. Ta predikcija može biti predstavljena kao numerička vrednost u regresionim zadacima ili kao verovatnoća pripadnosti određenoj klasi u klasifikacionim zadacima.

[8] Aktivaciona funkcija (eng. Activation function) - primenjuje se na zbir ulaznih vrednosti i njihovih težina pre generisanja izlaza neurona. Njena uloga je da uvede nelinearnost u model, čime se neuronskoj mreži omogućava učenje složenih obrazaca [15].



Slika 2. – Prikaz ilustracije arhitekture Feedforward neuronske mreže.

Slika 2. prikazuje Feedforward[9] neuronsku mrežu koja se sastoji od tri glavna dela: ulaznog sloja, više skrivenih slojeva i izlaznog sloja. Sa leve strane se nalaze ulazni neuroni (narandžasti čvorovi) koji predstavljaju sirove ulazne podatke. U sredini su skriveni slojevi (plavi čvorovi) koji kroz više međusobno povezanih neurona vrše transformaciju i ekstrakciju karakteristika. Sa desne strane je izlazni sloj (crveni čvor) koji daje konačnu predikciju modela.

2.3.1 AKTIVACIONA FUNKCIJA

Aktivaciona funkcija (eng. Activation function) primenjuje se na zbir ulaznih vrednosti i njihovih težina pre generisanja izlaza neurona. Njena uloga je da uvede nelinearnost u model, čime se neuronskoj mreži omogućava učenje složenih obrazaca [15].

Tipovi aktivacionih funkcija su [15]:

1. Linearna aktivaciona funkcija (eng. Linear Activation Function)

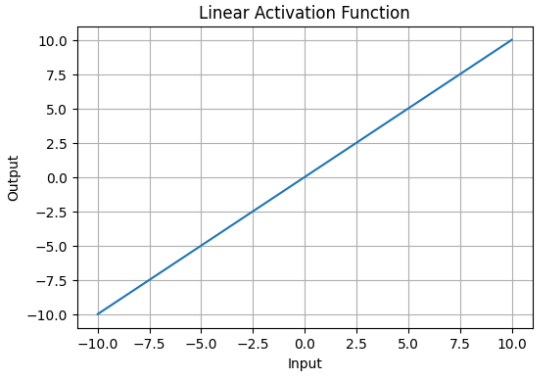
Linearna aktivaciona funkcija (eng. Linear Activation Function) predstavlja najjednostavniji oblik aktivacione funkcije i definiše se izrazom y=x, pri čemu je izlazna vrednost jednaka ulaznoj. Bez obzira na broj slojeva u neuronskoj mreži, ukoliko se u svim slojevima primenjuje isključivo linearna aktivaciona funkcija, model zadržava linearnu prirodu i nije u stanju da modeluje složene nelinearne odnose u podacima [15].

Osnovne karakteristike linearne aktivacione funkcije su [15]:

- izlazne vrednosti se nalaze u intervalu od $-\infty$ do $+\infty$;
- izlaz predstavlja linearnu transformaciju ulaznih vrednosti;
- ograničava izražajnu moć mreže kada se koristi bez nelinearnih funkcija;
- najčešće se primenjuje u izlaznom sloju modela za rešavanje regresionih problema;

[9] Feedforward neuronska mreža (eng. Feedforward Neural Network - FNN) predstavlja vrstu veštačke neuronske mreže kod koje se podaci obrađuju u jednom pravcu, od ulaznog ka izlaznom sloju, bez povratnih veza ili ciklusa u strukturi mreže. Ovaj tip mreže se najčešće koristi za zadatke prepoznavanja obrazaca, uključujući klasifikaciju slika i govora [16].

- u skrivenim slojevima se kombinuje sa nelinearnim aktivacionim funkcijama kako bi se omogućilo učenje složenijih obrazaca.



Slika 3. - Prikaz linearne aktivacione funkcije.

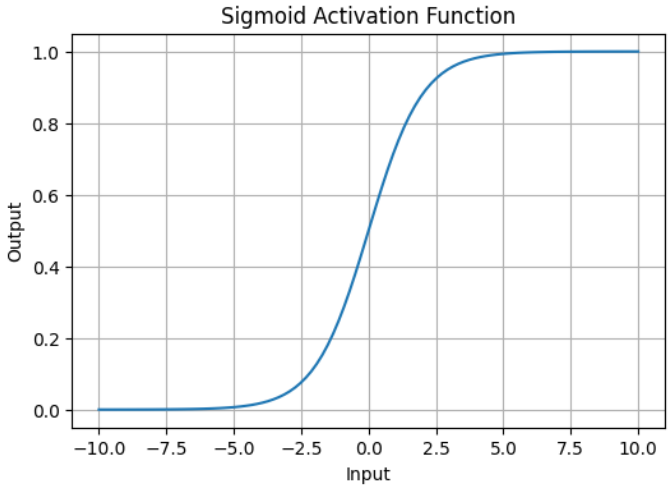
2. Nelinearne aktivacione funkcije (eng. Non-Linear Activation Functions)

2.1. Sigmoidna aktivaciona (eng. Sigmoid Function)

Sigmoidna aktivaciona funkcija (eng. Sigmoid Function) predstavlja jednu od najčešće korišćenih nelinearnih aktivacionih funkcija i karakteriše je S-oblika kriva. Ova funkcija omogućava postepeni i glatki prelaz između izlaznih vrednosti, što je čini pogodnom za optimizacione metode zasnovane na gradijentu [15].

Osnovne karakteristike [15]:

- izlazne vrednosti su ograničene na interval od 0 do 1, zbog čega se često primenjuje u problemima binarne klasifikacije;
- omogućava modelovanje nelinearnih odnosa između ulaznih i izlaznih podataka;
- najveću osetljivost pokazuje u opsegu ulaznih vrednosti približno između −2 i 2, gde male promene ulaza mogu značajno uticati na izlaz, što doprinosi efikasnijem učenju modela.



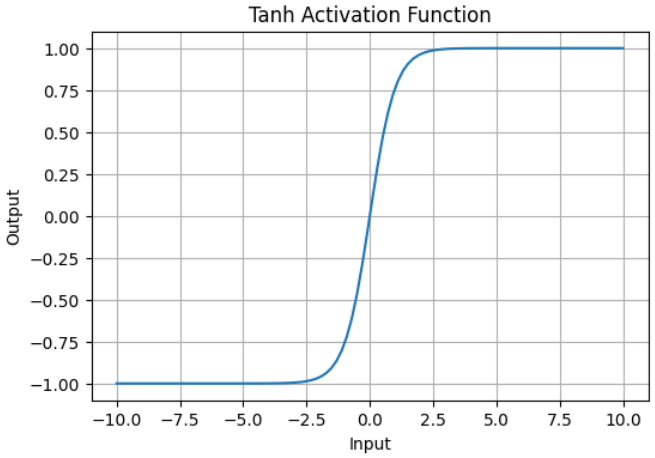
Slika 4. - Prikaz Sigmoidne aktivacione funkcije.

2.2. Tanh aktivaciona funkcija (eng. Tanh Activation Function – Tanh)

Tanh aktivaciona funkcija (eng. Tanh Activation Function – Tanh) predstavlja nelinearnu aktivacionu funkciju koja se može posmatrati kao proširena verzija sigmoidne funkcije. Za razliku od sigmoidne funkcije, koja mapira izlaz u opseg od 0 do 1, tanh funkcija generiše izlazne vrednosti u intervalu od −1 do 1, zbog čega je centrirana oko nulte vrednosti [15].

Osnovne karakteristike [15]:

- izlazne vrednosti su ograničene na interval od −1 do 1,
- omogućava efikasno modelovanje složenih nelinearnih odnosa u podacima,
- zbog izlaza centriranog oko nule često se primenjuje u skrivenim slojevima neuronskih mreža, jer doprinosi stabilnijem i bržem procesu učenja modela.



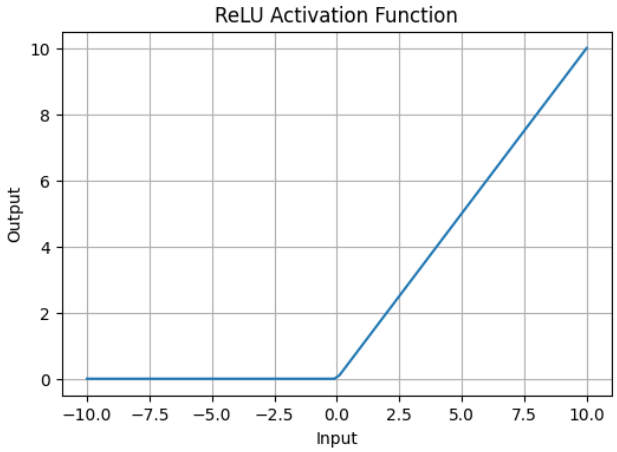
Slika 5. - Prikaz Tanh aktivacione funkcije.

2.3. ReLU aktivaciona funkcija (eng. Rectified Linear Unit – ReLU)

ReLU aktivaciona funkcija (eng. Rectified Linear Unit – ReLU) predstavlja jednu od najčešće primenjivanih nelinearnih aktivacionih funkcija u oblasti dubokog učenja. Ova funkcija vraća ulaznu vrednost ukoliko je ona pozitivna, dok u slučaju negativnih ulaza daje izlaz jednaku nuli [15].

Osnovne karakteristike [15]:

- izlazne vrednosti pripadaju intervalu od 0 do +∞;
- uvodi nelinearnost u model, čime omogućava učenje složenih obrazaca u podacima;
- odlikuje se jednostavnom i efikasnom računskom implementacijom, što doprinosi bržem procesu obuke;
- aktivira samo pozitivne vrednosti neurona, čime poboljšava efikasnost mreže;
- najčešće se koristi u skrivenim slojevima dubokih neuronskih mreža zbog dobrih performansi i stabilnog učenja.



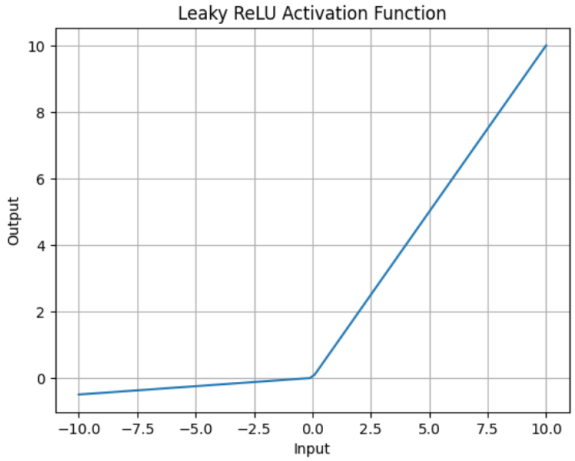
Slika 6. - Prikaz ReLU aktivacione funkcije.

2.4. Leaky ReLU aktivaciona funkcija (eng. Leaky Rectified Linear Unit – Leaky ReLU)

Leaky ReLU aktivaciona funkcija (eng. Leaky Rectified Linear Unit – Leaky ReLU) predstavlja modifikovanu verziju ReLU funkcije. Za razliku od standardne ReLU funkcije, koja za negativne ulazne vrednosti daje izlaz nula, Leaky ReLU uvodi mali nagib (najčešće $\alpha = 0{,}01$), čime omogućava da i negativni ulazi imaju mali, ali nenulti izlaz [16].

Osnovne karakteristike [15]:

- izlazne vrednosti pripadaju intervalu od $-\infty$ do $+\infty$;
- smanjuje pojavu problema „mrtvih“ neurona (eng. dying ReLU), kod kojih neuroni prestaju da aktiviraju izlaz;
- poboljšava protok gradijenata tokom procesa obuke modela;
- u određenim slučajevima može ostvariti bolje performanse u odnosu na standardnu ReLU funkciju, posebno kod dubokih neuronskih mreža.



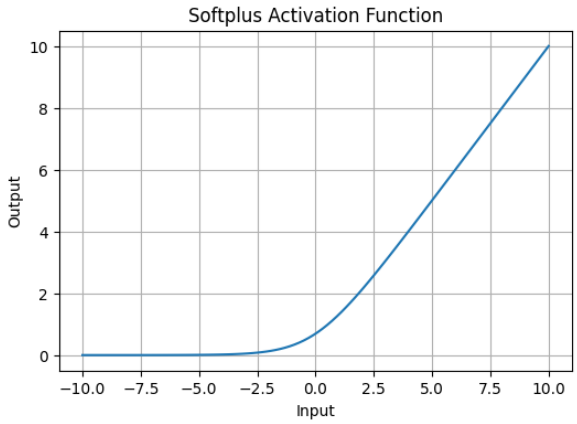
Slika 7. - Prikaz Leaky ReLU aktivacione funkcije.

2.5. Softplus aktivaciona funkcija (eng. Softplus Function)

Softplus aktivaciona funkcija (eng. Softplus Function) predstavlja nelinearnu aktivacionu funkciju koja se može posmatrati kao glatka aproksimacija ReLU funkcije. Za razliku od ReLU funkcije, Softplus ne sadrži nagle prelaze u vrednostima izlaza, već je u potpunosti diferencijabilna, što doprinosi stabilnijem i efikasnijem procesu optimizacije modela [15].

Osnovne karakteristike su [15]:

- izlazne vrednosti pripadaju intervalu od 0 do +∞;
- uvodi nelinearnost i omogućava modelovanje složenih obrazaca u podacima;
- predstavlja glatku i kontinuiranu funkciju bez diskontinuiteta karakterističnih za ReLU;
- zbog diferencijabilnosti može doprineti stabilnijem procesu obuke neuronskih mreža u određenim primenama.



Slika 8. - Prikaz Softplus aktivacione funkcije.

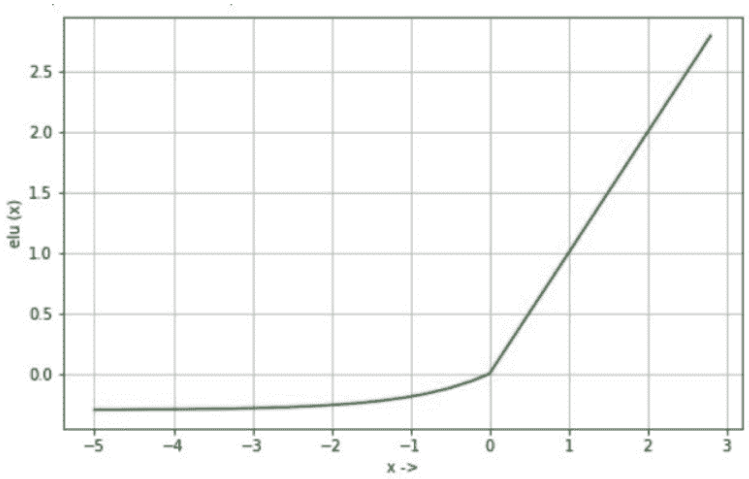
3. Eksponencijalne linearne jedinice (eng. Exponential Linear Unit – ELU)

3.1. Eksponencijalna linearna jedinica (eng, Exponential Linear Unit – ELU)

Eksponencijalna linearna jedinica (eng. Exponential Linear Unit – ELU) predstavlja nelinearnu aktivacionu funkciju koja doprinosi poboljšanju procesa učenja i ublažavanju problema nestajućeg gradijenta (eng. vanishing gradient). Za pozitivne ulazne vrednosti ponaša se kao ReLU funkcija, dok za negativne vrednosti koristi glatku eksponencijalnu transformaciju, čime omogućava kontinuiran prelaz izlaznih vrednosti [15].

Osnovne karakteristike [15]:

- izlazne vrednosti se nalaze u intervalu od $-\alpha$ do +∞;
- uvodi nelinearnost i omogućava modelovanje složenih obrazaca u podacima;
- omogućava i negativne izlaze, i time doprinosi vrednostima centriranim oko nule i stabilnijem učenju modela;
- predstavlja glatku i diferencijabilnu funkciju, što poboljšava optimizaciju i stabilnost procesa obuke neuronskih mreža.



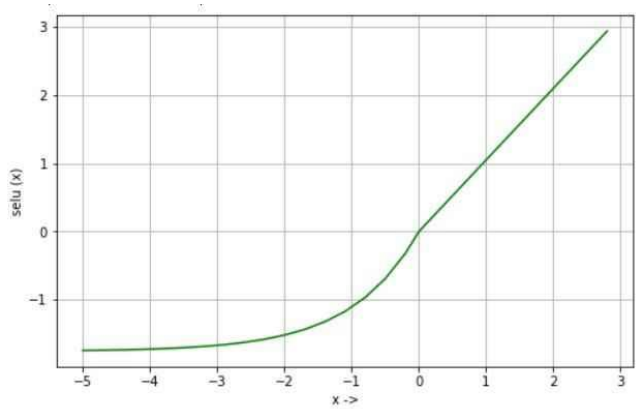
Slika 9. - Prikaz ELU funkcije.

3.2. Skalirana eksponencijalna linearna jedinica (eng. Scaled Exponential Linear Unit – SELU)

Skalirana eksponencijalna linearna jedinica (eng. Scaled Exponential Linear Unit – SELU) predstavlja proširenu verziju ELU aktivacione funkcije, razvijenu za primenu u samonormalizujućim neuronskim mrežama (self-normalizing neural networks). Zahvaljujući skalirajućim parametrima λ i α, SELU funkcija omogućava održavanje izlaznih vrednosti blizu nulte srednje vrednosti i približno jedinične varijanse, čime se postiže stabilniji proces učenja [15].

Osnovne karakteristike [15]:

- izlazne vrednosti se nalaze u intervalu od $-\lambda\alpha$ do $+\infty$;
- održava srednju vrednost izlaza bliskom nuli, uz varijansu približno jednaku jedan, što omogućava efekat samonormalizacije;
- doprinosi smanjenju problema nestajućeg i eksplodirajućeg gradijenta tokom procesa obuke (treniranja) modela;
- veoma je pogodna za duboke potpuno povezane neuronske mreže (eng. fully connected neural networks);
- u nekim slučajevima može smanjiti potrebu za primenom Batch Normalization tehnike.



Slika 10. - Prikaz SELU funkcije.

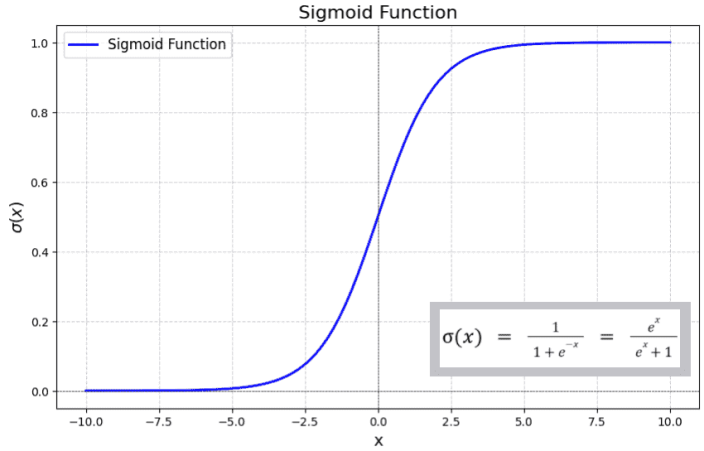
4. Aktivacione funkcije izlaznog sloja (eng. Output Layer Activation Functions)

4.1. Sigmoidna aktivaciona funkcija (eng. Sigmoid Activation Function)

Sigmoidna aktivaciona funkcija (eng. Sigmoid Activation Function) često se primenjuje u izlaznom sloju neuronskih mreža kod problema binarne klasifikacije. Ova funkcija mapira ulazne vrednosti u opseg od 0 do 1, pri čemu se izlaz može interpretirati kao verovatnoća pripadnosti određenoj klasi [15].

Osnovne karakteristike [15]:

- izlazne vrednosti su ograničene na interval od 0 do 1;
- omogućava interpretaciju izlaza kao verovatnoće;
- najčešće se koristi u izlaznom sloju modela za binarnu klasifikaciju;
- predstavlja diferencijabilnu i glatku funkciju, omogućavajući primenu optimizacionih metoda zasnovanih na gradijentu.



Slika 11. - Prikaz sigmoidne aktivacione funkcije.

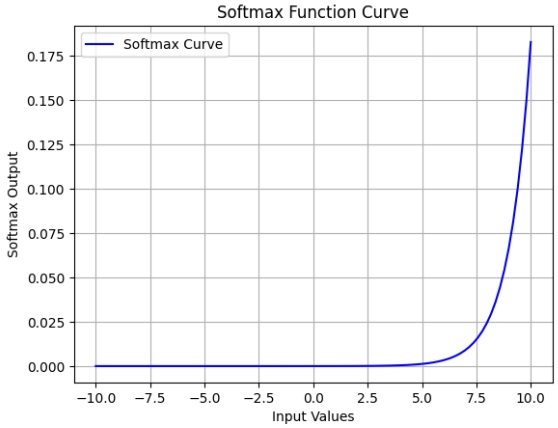
4.2. Softmax aktivaciona funkcija (eng. Softmax Function)

Softmax aktivaciona funkcija (eng. Softmax Function) najčešće se primenjuje u izlaznom sloju neuronskih mreža kod problema višeklasne klasifikacije. Osnovna svrha ove funkcije jeste transformacija sirovih izlaznih vrednosti modela u verovatnosnu raspodelu nad svim mogućim klasama [15].

Softmax funkcija mapira izlazne vrednosti u opseg od 0 do 1, pri čemu je zbir svih dobijenih verovatnoća jednak 1, omogućavajući njihovu direktnu interpretaciju kao verovatnoće pripadnosti pojedinim klasama [15].

Osnovne karakteristike [15]:

- transformiše izlazne vrednosti tako da se nalaze u intervalu od 0 do 1;
- obezbeđuje da zbir svih verovatnoća iznosi 1;
- ističe klasu sa najvećom verovatnoćom u odnosu na ostale;
- najčešće se koristi u izlaznom sloju modela za višeklasnu klasifikaciju;
- omogućava jednostavnu interpretaciju izlaza modela kao verovatnosne raspodele.



Slika 12. - Prikaz Softmax aktivacione funkcije.

2.3.2 KONVOLUCIONE NEURONSKE MREŽE (CNN)

Konvolucione neuronske mreže (eng. Convolutional Neural Networks – CNNs) predstavljaju arhitekture neuronskih mreža inspirisane načinom obrade vizuelnih informacija u ljudskom sistemu vida. Dizajnirane su za obradu slikovnih podataka kroz učenje prostornih odnosa između piksela [17].

Njihove osnovne karakteristike su [17]:

- da uče hijerarhijske reprezentacije karakteristika, od jednostavnih ivica do složenih objekata;
- prepoznaju prostorne obrasce primenom konvolucionih operacija;
- omogućavaju detekciju objekata nezavisno od njihove pozicije u slici;
- smanjuju računsku složenost fokusiranjem na lokalne regione umesto cele slike.

CNN predstavlja sekvencu slojeva, pri čemu svaki sloj transformiše ulazni tenzor u novi izlazni tenzor primenom diferencijabilne funkcije [17].

Slojevi unutar konvolucione neuronske mreže [17]:

1. Ulazni sloj (eng. Input Layer)

   Ulazni sloj prima sirove podatke slike i prosleđuje ih dalje kroz mrežu na obradu. U konvolucionim neuronskim mrežama ulaz se najčešće predstavlja kao trodimenzionalni tenzor (širina × visina × dubina).

   - Sadrži vrednost piksela
   - Čuva prostornu strukturu slike, što je važno za dalju ekstrakciju karakteristika
   - Filter (kernel) klizi preko slike i na svakoj poziciji vrši element-wise množenje sa odgovarajućim delom slike
   - Dobijene vrednosti se sabiraju i formiraju jednu izlaznu vrednost
   - Ova operacija se ponavlja kroz celu sliku uz definisan stride (korak pomeranja filtera)

- Rezultat predstavlja feature mapu, koja ističe uočene obrasce kao što su ivice, teksture i oblici
- Više filtera se koristi za ekstrakciju različitih karakteristika

2. Konvolucioni sloj (eng. Convolutional Layer)

Konvolucioni sloj ima zadatak da izdvoji ključne karakteristike iz ulaznih podataka. On koristi skup naučivih filtera (kernela) koji se pomeraju preko slike i računaju skalarni proizvod između težina filtera i odgovarajućih delova slike, čime se dobijaju mape karakteristika (eng. feature maps).

- Koristi male filtere za analizu slike
- Generiše obrasce kao što su ivice, teksture i oblici

3. Aktivacioni sloj (eng. Activation Layer)

Aktivacioni sloj uvodi nelinearnost u mrežu primenom aktivacione funkcije na izlaz konvolucionog sloja, što omogućava učenje složenih obrazaca.

- Najčešće se koriste ReLU, Tanh i Leaky ReLU funkcije
- Primena se vrši element po element na mapama karakteristika
- Dimenzije izlaza ostaju nepromenjene

4. Pooling sloj

Pooling sloj smanjuje prostornu dimenzionalnost mapa karakteristika, čime se smanjuje računarska složenost i rizik od preprilagođavanja (eng. overfitting). Obično se primenjuje između konvolucionih slojeva.

- Najčešće vrste su Max Pooling i Average Pooling
- Smanjuje širinu i visinu, dok dubina ostaje nepromenjena

5. Ravnanje (eng. Flattening)

Ravnanje pretvara višedimenzionalne mape karakteristika u jednodimenzionalni vektor, koji se dalje prosleđuje potpuno povezanim slojevima.

6. Fully Connected sloj

Potpuno povezani sloj koristi ekstraktovane karakteristike za donošenje odluke i formiranje izlaznih predikcija.

- Svaki neuron je povezan sa svim neuronima prethodnog sloja
- Služi za zaključivanje višeg nivoa na osnovu naučenih karakteristika

7. Izlazni sloj (Output Layer)

Izlazni sloj transformiše konačne rezultate u verovatnoće ili numeričke vrednosti u zavisnosti od tipa problema.

- Koristi Sigmoid funkciju za binarnu klasifikaciju
- Koristi Softmax funkciju za višeklasnu klasifikaciju
- Mala matrica (eng. matrix), poznat kao filter (kernel), pomera se preko ulazne slike kako bi izdvojila značajne karakteristike.
- Na svakoj poziciji, filter vrši množenje na nivou elemenata (eng. element-wise) sa odgovarajućim delom slike, nakon čega se dobijene vrednosti sabiraju i formiraju jednu izlaznu vrednost.
- Ova operacija se ponavlja kroz celu sliku uz definisan stride (korak pomeranja), pri čemu se kao rezultat dobija nova matrica, poznata kao feature mapa, koja ističe detektovane obrasce u podacima.
- Istovremeno se može primeniti veći broj filtera, čime se omogućava detekcija različitih karakteristika kao što su ivice, teksture i oblici. Ovakav pristup omogućava očuvanje prostornih odnosa u podacima, uz istovremeno smanjenje broja parametara u poređenju sa potpuno povezanim (eng. fully connected) slojevima.
- Kako bi se kontrolisale dimenzije izlaza i očuvale informacije sa ivica slike, primenjuje se padding, koji podrazumeva dodavanje dodatnih vrednosti oko granica ulazne slike.

2.3.3 RESNET18

ResNet18 model predstavlja varijantu Residual Network (ResNet) arhitekture i sastoji se od ukupno 18 slojeva. Osnovnu strukturu ove mreže čine rezidualni blokovi, koji uključuju skip connections (preskakačke veze) omogućavajući zaobilaženje jednog ili više slojeva [18].

Rezidualni blokovi su ključni za rešavanje problema nestajućeg gradijenta (eng. vanishing gradient), jer omogućavaju da mreža uči rezidualne funkcije umesto direktnog mapiranja ulaza na izlaz, čime se poboljšava protok gradijenata tokom procesa obuke i olakšava optimizacija modela [18].

Tipičan rezidualni blok u ResNet18 arhitekturi sastoji se od [18]:

- dve konvolucione (convolutional) sloja
- batch normalization sloja
- ReLU aktivacione funkcije

Skip connection dodaje ulaz bloka na izlaz drugog konvolucionog sloja, čime se omogućava učenje rezidualnih karakteristika. Ovakav pristup doprinosi bržoj konvergenciji i boljoj ukupnoj performansi modela.

Prednosti ResNet18 [19]:

- veoma brzo treniranje: model se trenira 3–5 puta brže u poređenju sa ViT modelima i približno 2 puta brže od ResNet-50 arhitekture
- lagana struktura: mali broj parametara i veličina modela (~45MB), što ga čini pogodnim za implementaciju u realnim sistemima
- efikasnost na malim skupovima podataka: postiže dobre rezultate čak i na manjim datasetovima (100+ slika)

- niska potrošnja memorije: može se trenirati na GPU-ovima od 4GB, a može raditi i na CPU uređajima
- brzo izvođenje predikcije: vreme inferencije iznosi približno 2–5 ms po slici na savremenim GPU-ovima
- stabilan bazni model: često se koristi kao pouzdana početna arhitektura za različite zadatke klasifikacije
- dobro dokumentovan: široko dostupna literatura i podrška zajednice

Nedostaci ResNet18 [19]:

- niža maksimalna tačnost: zaostaje za ResNet-101 i ViT Large modelima za oko 5–10% na velikim skupovima podataka
- ograničen kapacitet modela: može imati poteškoća u složenim ili fino-granularnim klasifikacionim zadacima
- plića arhitektura: manji broj slojeva ograničava učenje hijerarhijskih reprezentacija
- slabije iskorišćavanje velikih datasetova: ne koristi u potpunosti potencijal kada je dostupno mnogo podataka
- nije state-of-the-art: u scenarijima sa velikim količinama podataka nadmašuju ga modernije arhitekture

2.3.4 EFFICIENTNETB0

EfficientNetB0 arhitektura zasniva se na kompound skaliranju (compound scaling), koje istovremeno i ujednačeno skalira dubinu, širinu i rezoluciju mreže. Stem sloj predstavlja početni deo mreže koji ima zadatak da izvrši inicijalnu obradu ulazne slike pre nego što se ona prosledi dubljim slojevima [20].

U okviru EfficientNetB0 modela, stem sloj se sastoji od sledećih komponenti [20]:

- Konvolucioni sloj (Conv2D): 3×3 konvolucija sa korakom (stride) 2, čime se smanjuje prostorna dimenzionalnost ulaza
- Batch Normalization: normalizacija aktivacija radi stabilnijeg i bržeg treniranja modela
- Swish aktivaciona funkcija: glatka nelinearna funkcija koja poboljšava protok gradijenata i performanse učenja

Prednosti EfficientNet-a [21]:

EfficientNet postiže visoku tačnost uz manji broj parametara u poređenju sa modelima kao što su ResNet i DenseNet, što ga čini efikasnijim za treniranje i implementaciju. Takođe, predstavlja skalabilnu porodicu modela (B0–B7), pa se može prilagoditi različitim hardverskim zahtevima. Često se koristi u transfer učenju i pokazuje dobre rezultate na različitim zadacima računarskog vida.

Nedostaci EfficientNet-a [21]:

Kod većih varijanti modela (npr. B6 i B7) javlja se visoka potrošnja memorije i potreba za snažnim GPU-om. Performanse mogu opasti na skupovima podataka koji se

značajno razlikuju od ImageNet-a bez dodatnog fine-tuninga. Takođe, na starijem hardveru može biti sporiji zbog specifičnih MBConv slojeva.

2.4 EVALUCIONE METRIKE

Evaluacione metrike se koriste za procenu performansi modela mašinskog učenja i omogućavaju analizu njegove tačnosti i ispunjenosti zadatih ciljeva. One su važne iz više razloga [22]:

- performanse modela: omogućavaju procenu kvaliteta predikcija koje model daje
- različiti zadaci: primenjuju se u klasifikaciji, regresiji i klasterovanju
- izbor odgovarajuće metrike: pomažu u odabiru najprikladnijeg načina evaluacije modela
- bolje donošenje odluka: osiguravaju da model ispunjava definisane ciljeve

2.4.1 METRIKE ZA KLASIFIKACIJU

Klasifikacioni problemi imaju za cilj predviđanje diskretnih klasa, a performanse modela se procenjuju pomoću različitih evaluacionih metrika. Koriste se sledeće metrike [22]:

1. Tačnost (Accuracy)

Tačnost (eng. Accuracy) predstavlja osnovnu metriku za evaluaciju performansi klasifikacionih modela i pokazuje odnos između broja tačnih predikcija i ukupnog broja predviđanja.

Iako daje brz uvid u performanse modela, tačnost može biti obmanjujuća u slučaju nebalansiranih skupova podataka. Na primer, ako jedan skup podataka sadrži 90% uzoraka jedne klase i 10% druge, model koji uvek predviđa dominantnu klasu može postići 90% tačnosti, iako u potpunosti zanemaruje drugu klasu.

Zbog toga, visoka vrednost tačnosti ne mora nužno značiti i dobro opšte performanse modela, posebno kada postoji značajna neravnoteža između klasa.

2. Preciznost (Precision)

Preciznost (eng. Precision) predstavlja metriku koja meri koliki udeo pozitivnih predikcija modela je zaista tačan. Ova metrika je posebno važna u situacijama kada je cena lažno pozitivnih rezultata visoka, kao što su medicinske dijagnoze, gde pogrešno predviđanje bolesti može imati ozbiljne posledice.

Preciznost omogućava procenu pouzdanosti pozitivnih predikcija modela, odnosno koliko često je pozitivna prognoza zapravo tačna.

3. Recall (Odziv / Osetljivost)

Recall, poznat i kao osetljivost (eng. Sensitivity), predstavlja meru koja pokazuje koliki deo stvarno pozitivnih slučajeva je model ispravno prepoznao. Ova metrika je posebno

važna u situacijama kada je propuštanje pozitivnog slučaja (lažno negativan rezultat) ozbiljnije od lažno pozitivnih predikcija.

Recall se posebno koristi u domenima gde je ključno identifikovati sve pozitivne slučajeve, kao što su npr. medicinska dijagnostika ili detekcija bolesti.

4. F1 Score

F1 Score predstavlja harmonijsku sredinu preciznosti (precision) i odziva (recall), i koristi se kada je potrebno postići balans između ove dve metrike. On objedinjuje obe mere u jednu vrednost, pri čemu viši F1 skor ukazuje na bolji ukupni učinak modela. Opseg vrednosti F1 skora je od 0 do 1.

Iako visoka preciznost uz nizak recall može dati dobar rezultat u jednoj metrici, takav model često propušta značajan broj relevantnih instanci. Zbog toga F1 skor daje realniju sliku performansi, posebno u slučajevima neuravnoteženih podataka.

Macro F1 Score predstavlja evaluacionu metriku koja računa prosečnu vrednost F1 rezultata dobijenih zasebno za svaku klasu u višeklasnim ili višelabelnim problemima. Ova metrika se koristi za procenu kvaliteta modela u zadacima ekstrakcije entiteta i sličnim klasifikacionim problemima [23].

Macro F1 Score je posebno pogodan za evaluaciju generativnih AI sistema koji se koriste za zadatke prepoznavanja i izdvajanja entiteta u tekstu [23].

Osnovne karakteristike [23]:

- vrednost se kreće u opsegu od 0.0 do 1.0
- maksimalna vrednost 1.0 označava idealne predikcije
- rezultat predstavlja prosečnu F1 vrednost po klasama, čime se obezbeđuje balansirana evaluacija performansi

5. Logaritamski gubitak (engl. Logarithmic Loss – Log Loss)

Log loss predstavlja metriku koja meri nesigurnost predikcija modela mašinskog učenja. Ona kažnjava model kada dodeljuje niske verovatnoće tačnim klasama i na taj način procenjuje ne samo tačnost, već i sigurnost predikcija. Ova metrika se najčešće koristi u problemima višeklasne klasifikacije, gde je važno oceniti kvalitet procenjenih verovatnoća.

Cilj optimizacije je minimizacija vrednosti log loss-a, pri čemu niže vrednosti ukazuju na bolju tačnost i veću pouzdanost modela.

6. AUC i ROC kriva

AUC (Area Under Curve) i ROC kriva se koriste u binarnoj klasifikaciji za procenu performansi modela. AUC predstavlja sposobnost modela da pravilno rangira pozitivne u odnosu na negativne primere, pri čemu vrednosti variraju od 0 do 1 (veće vrednosti označavaju bolji model).

ROC kriva prikazuje odnos između True Positive Rate (TPR) i False Positive Rate (FPR) pri različitim pragovima odlučivanja, čime omogućava vizuelnu procenu balansa između osetljivosti i specifičnosti modela.

Osnovne metrike su:

- TPR (True Positive Rate): procenat ispravno prepoznatih pozitivnih slučajeva
- TNR (True Negative Rate): procenat ispravno prepoznatih negativnih slučajeva
- FPR (False Positive Rate): procenat negativnih slučajeva pogrešno klasifikovanih kao pozitivni
- FNR (False Negative Rate): procenat pozitivnih slučajeva pogrešno klasifikovanih kao negativni

Interpretacija AUC vrednosti:

- AUC = 1: savršen model
- AUC = 0.5: model ekvivalentan slučajnom pogađanju
- AUC < 0.5: model lošiji od slučajnog pogađanja

7. Matrica konfuzije (Confusion Matrix)

Matrica konfuzije predstavlja N × N matricu, gde N označava broj klasa koje model treba da predvidi.

Iz matrice konfuzije definišu se četiri osnovne kategorije:

- Tačno pozitivni (eng. True Positives): slučajevi kada je model ispravno predvideo Yes, a stvarna vrednost je takođe Yes
- Tačno negativni (eng. True Negatives): slučajevi kada je model ispravno predvideo No, a stvarna vrednost je takođe No
- Lažno pozitivni (eng. False Positives): slučajevi kada je model predvideo Yes, ali je stvarna vrednost No
- Lažno negativni (eng. False Negatives): slučajevi kada je model predvideo No, ali je stvarna vrednost Yes

2.5 MORFOLOŠKA KLASIFIKACIJA GALAKSIJA

Morfološka klasifikacija galaksija pruža vitalne fizičke informacije o orbitalnim kretanjima zvezda u galaksijama i dovodi do zanimljivih korelacija sa istorijom formiranja zvezda i drugim fizičkim svojstvima [26].

Morfološka klasifikacija galaksija predstavlja oblast sa tradicijom razvoja dužom od 100 godina, a mnogi naučnici su uvodili nove šeme klasifikacije, što je dovelo do ponekad zbunjujućeg niza terminologije i preklapanja klasa [26].

Uopšteno postoje tri tipa galaksija, koji dalje imaju svoje podtipe:

- Spiralne galaksije – karakterističog su izgleda i prepoznatljive su po svojim kracima, gde broj krakova može varirati, kao i njihov stepen uvijanja,

- Eliptične galaksije – ove galaksije nemaju krakove,
- Iregularne galaksije – ovo su galaksije čiji je oblik iregularan, iz mnoštva razlova (npr. spajanje dve ili više galaksija).

2.6 GALAXY ZOO 2

Galaxy Zoo je projekat građanske nauke (citizen science) koji omogućava volonterima da klasifikuju galaksije na osnovu njihovog oblika sa astronomskih snimaka. Projekat je započet kako bi se iskoristila ljudska sposobnost vizuelnog prepoznavanja obrazaca u velikim astronomskim skupovima podataka, posebno iz Sloan Digital Sky Survey (SDSS) baze podataka [24].

Galaxy Zoo 2 (GZ2) predstavlja proširenu verziju originalnog Galaxy Zoo projekta i sadrži detaljnije morfološke klasifikacije za 304,122 galaksije iz SDSS kataloga. Umesto osnovne podele (spiralne, eliptične, sudari), GZ2 omogućava finije opise struktura galaksija, kao što su spiralne ruke, šipke (bars), izbočine (bulges) i orijentacija diskova [25].

Citizen science (građanska nauka) je oblik naučnog istraživanja u kojem učestvuju neprofesionalni naučnici (volonteri). Oni doprinose prikupljanju, analizi i klasifikaciji podataka, što omogućava obradu ogromnih datasetova koje bi bilo teško analizirati samo od strane naučnika [25].

Sloan Digital Sky Survey (SDSS) je veliki astronomski projekat koji snima slike miliona galaksija i nebeskih objekata pomoću teleskopa. Ove slike se koriste u Galaxy Zoo projektima kao osnovni ulazni podaci za vizuelnu klasifikaciju galaksija [25].

SDSS (Sloan Digital Sky Survey) je veliki astronomski projekat koji obezbeđuje slike i podatke o galaksijama za naučna istraživanja. U okviru Galaxy Zoo 2 korišćen je DR7 (Data Release 7) Legacy katalog, koji sadrži opservacije najbližih, najsvetlijih i najvećih galaksija kako bi se omogućila detaljna analiza njihovih morfoloških karakteristika [25].

Za potrebe GZ2 odabrane su galaksije sa ograničenjima po svetlini, veličini i crvenom pomaku, kako bi se obezbedili kvalitetni podaci pogodni za vizuelnu klasifikaciju struktura galaksija [25].

U Galaxy Zoo 2, svaka slika galaksije se prikazuje velikom broju korisnika koji odgovaraju na niz pitanja (decision tree sistem) [25].

- Svaka galaksija dobija više nezavisnih odgovora (glasova) od različitih korisnika
- Glasovi se kombinuju u procenat odgovora (vote fraction)
- Koriste se i težinski sistemi kako bi se smanjio uticaj nepouzdanih korisnika
- Konačna klasifikacija predstavlja statistički objedinjene rezultate svih glasova

Jedna galaksija u Galaxy Zoo 2 sistemu nikada nema samo jedan odgovor, već [25]:

- na nju odgovaraju desetine ili stotine volontera
- svi odgovori se kombinuju u statistički rezultat

- konačna klasifikacija je zasnovana na distribuciji odgovora, a ne na jednom glasu

Ovo povećava tačnost jer se smanjuje uticaj grešaka pojedinačnih korisnika.

2.6.1 OZNAKE (LABELE) U GALAXY ZOO 2

U okviru projekta Galaxy Zoo 2, svaka galaksija dobija oznaku (labelu) koja predstavlja kombinaciju različitih morfoloških karakteristika uočenih tokom procesa klasifikacije. Za razliku od jednostavne podele na spiralne i eliptične galaksije, GZ2 koristi hijerarhijski sistem pitanja (eng. Decision Tree) kojim se identifikuju detaljne osobine svake galaksije [25].

Oznake se formiraju kombinovanjem odgovora na više pitanja koja opisuju različite morfološke karakteristike, kao što su oblik galaksije, prisustvo spiralnih krakova, centralne šipke (eng. bar), prstena (eng. ring), dominantnost centralnog ispupčenja (eng. bulge) i druge strukturne osobine. Na primer [25]:

Zbog velikog broja mogućih kombinacija odgovora u okviru Decision Tree sistema, u Galaxy Zoo 2 postoji čak 818 različitih oznaka. Svaka oznaka predstavlja jedinstvenu kombinaciju morfoloških karakteristika, umesto samo jednog tipa galaksije. Na ovaj način moguće je mnogo detaljnije opisati strukturu galaksija nego korišćenjem tradicionalne Hablove klasifikacije [25].

Takav pristup omogućava preciznije proučavanje morfologije galaksija i predstavlja jedan od razloga zbog kojih se Galaxy Zoo 2 često koristi kao referentni skup podataka za razvoj i evaluaciju modela mašinskog i dubokog učenja [25].

Broj od 818 oznaka ne predstavlja 818 različitih tipova galaksija, već 818 mogućih kombinacija odgovora koje nastaju prolaskom kroz Decision Tree. Svako pitanje u stablu (npr. Da li galaksija ima disk?, Da li postoji centralna šipka?, Koliko spiralnih krakova ima?, Da li je prisutan prsten?) dodaje novu informaciju, a kombinovanjem svih odgovora formira se konačna oznaka galaksije [25].

Ovakav sistem omogućava da jedna oznaka istovremeno sadrži informacije o [25]:

- osnovnoj morfologiji (eliptična ili spiralna),
- prisustvu centralne šipke (bar),
- spiralnim kracima (spiral arms),
- prstenu (ring),
- veličini centralnog ispupčenja (bulge),
- orijentaciji diska i drugim morfološkim osobinam

2.7 BINARNA KLASIFIKACIJA

Iz razloga što ovaj skup podataka ima čak 818 različitih, odnosno jedinstvenih kombinacija, za rad je odabrano mapiranje ovih 818 jedinstvenih kombinacija na samo dve i to preko početnog slova oznake klasifikacije.

Početno veliko slovo u ovom skupu podataka ima moguće četiri varijante:

- A – artifakti ili zvezde (eng. Artifacts or Stars),
- E – eliptične/glatke galaksije (eng. Elliptical / Smooth galaxy),
- S – spiralne galaksije (eng. Spiral galaxy),
- I – iregularne galaksije / nešto drugo (galaksije iregularnog oblika poput „sudara“ – eng. mergers – ili nešto drugo poput preklapanja galaksija – eng. overlap).

3 METODOLOŠKI OKVIR ISTRAŽIVANJA

3.1 PROBLEM ISTRAŽIVANJA

Problem istraživanja odnosi se na utvrđivanje u kojoj meri izbor arhitekture neuronske mreže utiče na tačnost i pouzdanost binarne klasifikacije galaksija. Iako se različite arhitekture dubokog učenja uspešno primenjuju u zadacima klasifikacije slika, nije unapred poznato koja od posmatranih arhitektura (CNN, ResNet18 ili EfficientNetB0) ostvaruje najbolje rezultate na skupu podataka Galaxy Zoo 2 pri identičnim uslovima treniranja i evaluacije. Zbog toga je potrebno izvršiti komparativnu analizu njihovih performansi primenom jedinstvene metodologije i istih evaluacionih metrika.

3.2 PREDMET ISTRAŽIVANJA

Predmet istraživanja predstavlja analiza uticaja različitih arhitektura neuronskih mreža na uspešnost binarne morfološke klasifikacije galaksija korišćenjem skupa podataka Galaxy Zoo 2. Istraživanje obuhvata razvoj, obuku i evaluaciju tri arhitekture dubokog učenja – klasične konvolucione neuronske mreže (CNN), ResNet18 i EfficientNetB0 – sa ciljem utvrđivanja njihovih performansi u razlikovanju spiralnih (S) i glatkih (E) galaksija pod istim uslovima treniranja i testiranja.

3.3 CILJ ISTRAŽIVANJA

Komparativno evaluirati i uporediti različite arhitekture dubokog učenja (CNN, ResNet18 i EfficientNetB0) za binarnu klasifikaciju binarno mapiranih Galaxy Zoo 2 labela, identifikovati model sa najboljim ukupnim performansama (metrika macro-F1) i analizirati razlike u kvalitetu predikcija između klasa (S i E).

3.4 ZADACI ISTRAŽIVANJA

Da bi se ostvario glavni cilj, u okviru rada su definisani sledeći zadaci:

1. Analizirati osnovne teorijske koncepte mašinskog učenja i dubokog učenja, sa posebnim osvrtom na konvolucione neuronske mreže i njihove primene u obradi slika,
2. Istražiti problem automatske morfološke klasifikacije galaksija i značaj binarne klasifikacije (eliptične i spiralne galaksije),
3. Pripremiti i obraditi skup astronomskih podataka iz Galaxy Zoo 2 baze, uključujući filtriranje i balansiranje klasa,
4. Razviti i implementirati ML pipeline za treniranje i evaluaciju modela CNN, ResNet18 i EfficientNetB0,
5. Izvršiti eksperimentalno poređenje performansi modela korišćenjem standardnih metrika (Accuracy, Precision, Recall, F1-score i macro-F1),
6. Analizirati rezultate i utvrditi koji model daje najbolje performanse u zadatku klasifikacije galaksija,
7. Formulisati zaključke o uticaju arhitekture modela na tačnost i generalizaciju u problemu klasifikacije astronomskih slika.

3.5 HIPOTEZA ISTRAŽIVANJA

Polazna pretpostavka ovog istraživanja se zasniva na tome da različite arhitekture neuronskih mreža ne ostvaruju jednake performanse u zadacima klasifikacije fotografija galaksija. Pretpostavlja se da savremenije arhitekture dubokog učenja omogućavaju preciznije izdvajanje relevantnih karakteristika sa astronomskih fotografija galaksija, što se odražava na veću tačnost i pouzdanost klasifikacije.

U skladu sa tim, postavljena je sledeća hipoteza:

Arhitekture ResNet18 i EfficientNetB0 će ostvariti statistički značajno bolji macro-F1 od klasičnog CNN-a u binarnoj klasifikaciji galaksija nad Galaxy Zoo 2 skupom podataka, pod istim uslovima treninga i evaluacije.

3.6 METOD ISTRAŽIVANJA

Metodologija istraživanja zasniva se na kombinaciji teorijskog i eksperimentalnog pristupa. U teorijskom delu analizirani su osnovni pojmovi iz oblasti mašinskog učenja, dubokog učenja i konvolucionih neuronskih mreža, kao i relevantne evaluacione metrike.

Eksperimentalni deo realizovan je kroz implementaciju ML pipeline-a u Python-u, korišćenjem TensorFlow i Keras biblioteka. Korišćen je skup podataka Galaxy Zoo 2, pri čemu je problem reduciran na binarnu klasifikaciju galaksija (eliptične i spiralne).

Podaci su prethodno obrađeni, balansirani i podeljeni na trening, validacioni i test skup. Implementirani su CNN, ResNet18 i EfficientNetB0 modeli, pri čemu EfficientNet koristi transferno učenje.

Trening je unapređen korišćenjem callback mehanizama (EarlyStopping, ReduceLROnPlateau i ModelCheckpoint). Evaluacija je izvršena pomoću metrika Accuracy, Precision, Recall, F1-score i macro-F1, uz dodatnu analizu matrice konfuzije.

Dobijeni rezultati korišćeni su za komparativnu analizu performansi modela.

3.7 INSTRUMENTI ISTRAŽIVANJA

U svrhu realizovanja eksperimentalnog istraživanja korištene su sledeće tehnologije:

3.7.1 VISUAL STUDIO CODE

Za realizaciju ovog eksperimenta korišćeno je programsko okruženje Visual Studio Code, kao praktičan editor za razvoj i upravljanje kodom [27].

U okviru ovog programskog okruženja u svrhu realizacije eksperimenta korištene su ekstenzije (eng. extenstions) Python, Pylance, Python Debugge, Python Environment, a takođe su korištene biblioteke: os, random, numpy, tensorflow, matplotlib, sklearn, astropy i pandas.

3.7.2 GALAXY ZOO 2 PODACI

U cilju izvođenja što realnijeg eksperimenta korišćeni su stvarni opservacioni podaci iz Galaxy Zoo 2 projekta [28], odnosno SDSS (Sloan Digital Sky Survey) [29] slike galaksija. Preko distributivnog servisa arXiv [30] preuzeta je ukupna kolekcija od više od 230.000 instanci (slika), ali je zbog ograničenih računarskih resursa u radu korišćen podskup od 4.000 slika, odabran u svrhu sprovođenja analize i testiranja modela.

Preko Galaxy Zoo [31] projekta preuzet je fajl formata .fits („gz2_hart16.fits“ [31]) koji sadrži podatke o klasifikaciji svake pojedine galaksije iz Galaxy Zoo 2 [31] projekta.

4 EKSPERIMENTALNO ISTRAŽIVANJE

Eksperimentalni deo istraživanja sproveden je kroz razvoj i evaluaciju modela dubokog učenja za automatsku morfološku klasifikaciju galaksija na osnovu njihovih astronomskih snimaka. Cilj eksperimenta bio je da se ispita i uporedi uspešnost različitih arhitektura konvolucionih neuronskih mreža u klasifikaciji galaksija na dve morfološke klase – eliptične (E) i spiralne (S).

U okviru eksperimenta korišćen je skup podataka Galaxy Zoo 2, iz kojeg je formiran balansiran skup slika galaksija. Nakon pripreme podataka, izvršena je podela na skupove za obuku, validaciju i testiranje, pri čemu su svi modeli trenirani pod istim uslovima kako bi se obezbedilo objektivno poređenje njihovih performansi. U istraživanju su implementirana i evaluirana tri modela: konvoluciona neuronska mreža (CNN), ResNet18 i EfficientNetB0. Kod modela EfficientNetB0 dodatno je primenjen postupak finog podešavanja (fine-tuning) radi prilagođavanja prethodno naučenih karakteristika konkretnom problemu klasifikacije galaksija.

Performanse svakog modela procenjene su na test skupu korišćenjem standardnih metrika za evaluaciju klasifikacionih modela, uključujući tačnost (Accuracy), preciznost (Precision), odziv (Recall), F1-meru (F1-score), kao i matricu konfuzije. Dobijeni rezultati omogućili su međusobno poređenje modela i analizu njihovih prednosti i ograničenja u zadatku automatske morfološke klasifikacije galaksija, čime je izvršena provera postavljene hipoteze istraživanja.

4.1 OPIS ISTRAŽIVANJA

Svrha eksperimentalnog istraživanja jeste provera hipoteze rada kroz razvoj, obuku i evaluaciju modela dubokog učenja za automatsku morfološku klasifikaciju galaksija. Istraživanje ima za cilj da utvrdi u kojoj meri različite arhitekture konvolucionih neuronskih mreža mogu uspešno klasifikovati galaksije na eliptične (E) i spiralne (S), kao i da se međusobno uporede njihove performanse.

Eksperimentalni deo istraživanja realizovan je primenom programskog jezika Python i biblioteke TensorFlow/Keras za implementaciju modela dubokog učenja. Kao izvor podataka korišćen je javno dostupan skup podataka Galaxy Zoo 2, koji sadrži astronomske snimke galaksija zajedno sa njihovim morfološkim oznakama. Nakon pripreme podataka izvršena je njihova podela na skupove za obuku, validaciju i testiranje, pri čemu je formiran balansiran skup podataka koji obuhvata jednak broj eliptičnih i spiralnih galaksija.

U okviru istraživanja implementirana su i analizirana tri modela: konvoluciona neuronska mreža (CNN), ResNet18 i EfficientNetB0. Svi modeli obučavani su pod istim uslovima kako bi se obezbedilo objektivno poređenje njihovih performansi, dok je kod modela EfficientNetB0 dodatno primenjen postupak finog podešavanja (fine-tuning) radi prilagođavanja prethodno naučenih karakteristika konkretnom zadatku klasifikacije.

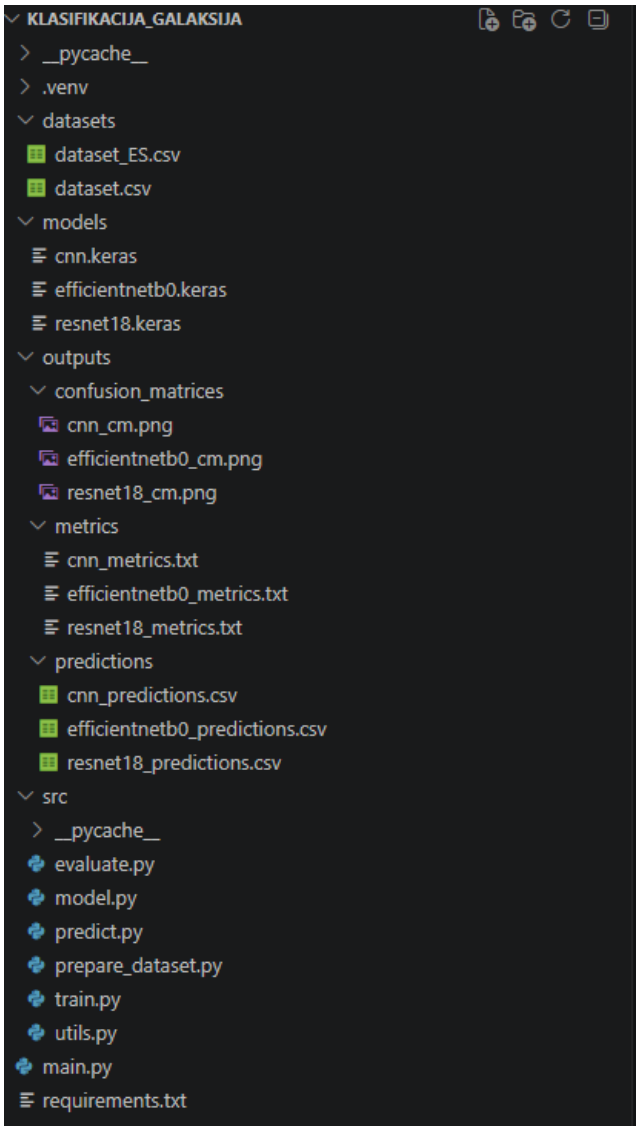
Rezultati klasifikacije evaluirani su korišćenjem standardnih metrika za procenu uspešnosti modela, uključujući tačnost (Accuracy), preciznost (Precision), odziv (Recall), F1-meru (F1-score) i matricu konfuzije (eng. Confusion Matrix). Dobijeni

rezultati predstavljaju osnovu za poređenje implementiranih modela i proveru postavljene hipoteze istraživanja.

4.2 IMPLEMENTACIJA EKSPERIMENTALNOG SISTEMA

Eksperimentalni sistem razvijen je u programskom jeziku Python korišćenjem biblioteka TensorFlow, Keras, Pandas, NumPy, Scikit-learn, Astropy i Matplotlib. Sistem predstavlja kompletan pipeline za pripremu podataka, treniranje, evaluaciju i testiranje modela dubokog učenja namenjenih klasifikaciji galaksija na eliptične i spiralne.

Projekat je organizovan u više modula, pri čemu svaki modul ima jasno definisanu funkcionalnost. Glavni program (main.py) upravlja kompletnim tokom izvršavanja sistema, dok se ostale funkcionalnosti nalaze u zasebnim modulima unutar direktorijuma src. Pored izvornog koda, projekat sadrži direktorijume za skupove podataka, sačuvane modele i rezultate eksperimenata.



Slika 13. – Prikaz organizacije direktorijuma i poddirektorijuma unutar projekta.

4.2.1 PRIPREMA SKUPA PODATAKA

Priprema podataka predstavlja prvi korak eksperimentalnog sistema. Za potrebe istraživanja korišćen je Galaxy Zoo 2 skup podataka koji sadrži FITS katalog astronomskih objekata, mapiranje identifikatora objekata na slike galaksija i JPEG slike galaksija.

Modul prepare_dataset.py zadužen je za pripremu početnog skupa podataka. Najpre se učitavaju FITS katalog i tabela za mapiranje identifikatora objekata na odgovarajuće slike. Nakon toga se iz oznake gz2_class izdvajaju četiri osnovne klase galaksija:

- A – artefakti ili zvezde (eng. artifacts or stars),
- E – eliptične / glatke galaksije (eng. Elliptical / Smooth galaxies),
- S – spiralne galaksije (eng. Spiral galaxies),
- I – iregularne / nešto drugo (eng. Irregular / Other).

Nakon spajanja tabela proverava se postojanje svake slike na disku, pri čemu se iz skupa podataka uklanjaju svi zapisi za koje odgovarajuća slika nije pronađena.

Pošto je cilj istraživanja binarna klasifikacija, iz kompletnog skupa podataka izdvajaju se samo galaksije klasa „E“ i „S“. Rezultat ovog procesa predstavlja novi skup podataka „*dataset_ES.csv*“ koji sadrži putanju do slike i pripadajuću oznaku klase.

	A	B	C	D	E
1	image_path,label				
2	D:/Downloads_3/GZ_2/imgs/images\58957.jpg,S				
3	D:/Downloads_3/GZ_2/imgs/images\193641.jpg,S				
4	D:/Downloads_3/GZ_2/imgs/images\55934.jpg,E				
5	D:/Downloads_3/GZ_2/imgs/images\158501.jpg,S				
6	D:/Downloads_3/GZ_2/imgs/images\110939.jpg,E				
7	D:/Downloads_3/GZ_2/imgs/images\249897.jpg,E				
8	D:/Downloads_3/GZ_2/imgs/images\71801.jpg,E				
9	D:/Downloads_3/GZ_2/imgs/images\87614.jpg,S				
10	D:/Downloads_3/GZ_2/imgs/images\113304.jpg,E				

Slika 14. – Prikaz izgleda skupa podataka „dataset_ES.csv”.

4.2.2 UZORKOVANJE I PODELA PODATAKA

Po završetku pripreme podataka vrši se balansiranje skupa podataka. Iz svake klase nasumično se bira jednak broj primera kako bi se izbegao uticaj neuravnoteženosti klasa tokom treniranja modela.

U ovom istraživanju korišćeno je ukupno 4000 slika, odnosno po 2000 slika za svaku klasu.

Podskup od 4000 slika, originalnog skupa koji sadrži preko 200 000 galaksija izabran je zbog ograničenja raspoloživih hardverskih resursa. Zbog ovog ograničenja hardvera, kompletan proces treniranja sva tri modela mašinskog učenja izvršen je putem CPU-a, umesto GPU-a i samim tim je rezultovao u drastično dužim vremenskim intervalima potrebnih za treniranje modela.

Nakon toga oznake klasa konvertuju se u numerički oblik:

- E - 0
- S – 1

Dobijeni skup podataka deli se na tri međusobno nezavisna dela:

- trening skup (80%),
- validacioni skup (10%),
- test skup (10%).

Prilikom podele korišćena je stratifikacija kako bi odnos klasa ostao jednak u svim skupovima podataka.

4.2.3 OBRADA SLIKA

Prilikom učitavanja svaka slika prolazi kroz nekoliko koraka predobrade.

Najpre se JPG (.jpg) slika učitava sa diska, nakon čega se dekodira u RGB format i skalira na rezoluciju 224 × 224 piksela. Zatim se pikseli konvertuju u tip float32.

Za CNN i ResNet18 modele vrši se normalizacija vrednosti piksela u interval [0,1], dok se za EfficientNetB0 koristi funkcija preprocess_input() koja odgovara načinu predobrade korišćenom tokom ImageNet pretreniranja.

Nakon učitavanja slike proverava se da li postoje nevalidne numeričke vrednosti (NaN), čime se sprečava prekid procesa treniranja.

Kako bi se ubrzalo izvršavanje sistema, TensorFlow tf.data API koristi paralelno učitavanje podataka, grupisanje u mini-batcheve i automatsko preuzimanje narednih podataka (prefetch).

4.2.4 IMPLEMENTACIJA MODELA DUBOKOG UČENJA

U okviru istraživanja implementirana su tri različita modela dubokog učenja:

- Konvoluciona neuronska mreža (CNN),
- ResNet18,
- EfficientNetB0.

Modeli su implementirani korišćenjem TensorFlow/Keras biblioteke i nalaze se u modulu model.py.

CNN predstavlja osnovni model razvijen od početka korišćenjem tri konvoluciona bloka, MaxPooling slojeva i potpuno povezanih slojeva za klasifikaciju.

ResNet18 implementiran je korišćenjem funkcionalnog API-ja i rezidualnih blokova koji omogućavaju efikasnije treniranje dubljih mreža putem rezidualnih veza između slojeva.

EfficientNetB0 predstavlja transfer learning model baziran na unapred istreniranim ImageNet težinama. Tokom prve faze treniranja svi slojevi osnovne mreže ostaju zamrznuti, dok se trenira samo završni klasifikacioni sloj.

Nakon završetka osnovnog treniranja izvršava se fine-tuning, pri čemu se odmrzava poslednjih dvadeset slojeva osnovne mreže i model se dodatno trenira sa manjom stopom učenja.

4.2.5 PROCES TRENIRANJA MODELA

Proces treniranja implementiran je u modulu "train.py".

Za sva tri modela korišćena je binarna funkcija gubitka *Binary Crossentropy* i *Adam* optimizacioni algoritam.

Tokom treniranja korišćene su sledeće tehnike:

- Data Augmentation,
- Early Stopping,
- Reduce Learning Rate on Plateau,
- Model Checkpoint.

Data augmentation se koristi za generisanje novih varijacija trening slika primenom horizontalnog okretanja, rotacije i zumiranja, čime se povećava robusnost modela.

Callback EarlyStopping prekida treniranje ukoliko se validaciona tačnost ne poboljšava određeni broj epoha, dok ReduceLROnPlateau automatski smanjuje stopu učenja kada validaciona tačnost stagnira.

Najbolja verzija modela automatski se čuva korišćenjem ModelCheckpoint callback-a.

Kod EfficientNetB0 modela nakon završetka osnovnog treniranja sledi faza fine-tuninga u kojoj se odmrzava deo backbone mreže i vrši dodatno prilagođavanje ImageNet težina konkretnom problemu klasifikacije galaksija.

4.2.6 EVALUACIJA MODELA

Evaluacija modela realizovana je u modulu „evaluate.py".

Nakon učitavanja sačuvanog modela vrši se predikcija nad test skupom podataka.

Na osnovu dobijenih verovatnoća generišu se binarne klasifikacije korišćenjem praga od 0,5.

Za procenu uspešnosti modela izračunavaju se sledeće metrike:

- Accuracy
- Precision
- Recall
- F1-score
- Macro F1-score.

Pored numeričkih metrika generiše se i matrica konfuzije koja omogućava detaljniju analizu uspešnosti klasifikacije obe klase galaksija.

Rezultati evaluacije automatski se čuvaju u direktorijumu outputs, pri čemu se posebno čuvaju tekstualne metrike, matrice konfuzije i tabela sa predikcijama svih test primera.

4.2.7 ORGANIZACIJA IZLAZNIH REZULTATA

Radi lakše analize eksperimenata sistem automatski organizuje sve generisane rezultate u odgovarajuće direktorijume.

Direktorijum „models“ – sadrži istrenirane modele u Keras (.keras) formatu.

Direktorijum „outputs/metrics“ – sadrži tekstualne (.txt) izveštaje sa vrednostima svih evaluacionih metrika.

Direktorijum „outputs/confusion_matrices“ –sadrži matrice konfuzije generisane za svaki model u PNG (.png) formatu.

Direktorijum „outputs/predictions“ – sadrži CSV (.csv) datoteke koje za svaku test sliku beleže stvarnu klasu, predikciju modela i procenjenu verovatnoću pripadnosti klasi spiralnih galaksija.

4.3 ANALIZA REZULTATA

U ovom poglavlju biće prikazani i analizirani rezultati dobijeni eksperimentalnim poređenjem tri modela dubokog učenja za binarnu klasifikaciju galaksija na eliptične (E) i spiralne (S). Analiza se zasniva na rezultatima evaluacije izvršene nad test skupom podataka koji nije korišćen tokom procesa treniranja modela.

Za procenu uspešnosti modela korišćene su standardne metrike klasifikacije:

- Accuracy,
- Precision,
- Recall,
- F1-score,
- Macro F1-score.

Pored numeričkih metrika analizirane su i matrice konfuzije, koje omogućavaju detaljniji uvid u tipove grešaka koje modeli prave prilikom klasifikacije.

4.3.1 REZULTATI EVALUACIJE MODELA

U daljem tekstu biće navedeni rezultati evaluacije sva tri modela mašinskog učenja.

Prikaz metrika sva tri modela mašinskog učenja (CNN, ResNet18 i EfficientNetB0) se može naći u tabeli 1.

Tabela 1. – Prikaz metrika za sva tri modela mašinskog učenja

Model	Accuracy	Precision	Recall	F1	macro-F1
CNN	0.6375	0.6279	0.6750	0.6506	0.6370
ResNet18	0.8100	0.8100	0.8100	0.8100	0.8100

EfficientNetB0	0.7825	0.7811	0.7850	0.7830	0.7825

Nakon evaluacije sva tri modela nad test skupom podataka izračunate su standardne metrike klasifikacije: tačnost (Accuracy), preciznost (Precision), odziv (Recall), F1-score i Macro F1-score. Dobijeni rezultati prikazani su u Tabeli 1.

Iz prikazanih rezultata može se uočiti da je ResNet18 ostvario najbolje performanse među svim analiziranim modelima. Ovaj model postiže vrednost od 0,8100 za sve posmatrane metrike, što ukazuje na veoma uravnoteženu sposobnost pravilnog prepoznavanja obe klase galaksija. Jednake vrednosti preciznosti i odziva znače da model podjednako uspešno identifikuje spiralne i eliptične galaksije, bez izražene sklonosti ka jednoj od klasa.

EfficientNetB0 ostvario je nešto slabije rezultate u odnosu na ResNet18, pri čemu je tačnost klasifikacije iznosila 0,7825, dok je F1-score bio 0,7830. Iako koristi transfer learning i unapred naučene reprezentacije sa ImageNet skupa podataka, u ovom eksperimentu nije nadmašio ResNet18. Razlika između preciznosti (0,7811) i odziva (0,7850) je veoma mala, što ukazuje na stabilno ponašanje modela tokom klasifikacije.

Najslabije rezultate ostvario je osnovni CNN model. Njegova tačnost iznosi 0,6375, dok je F1-score 0,6506. Vrednost odziva (0,6750) nešto je viša od preciznosti (0,6279), što pokazuje da model uspešnije pronalazi spiralne galaksije, ali pritom pravi veći broj pogrešnih pozitivnih klasifikacija u odnosu na druga dva modela.

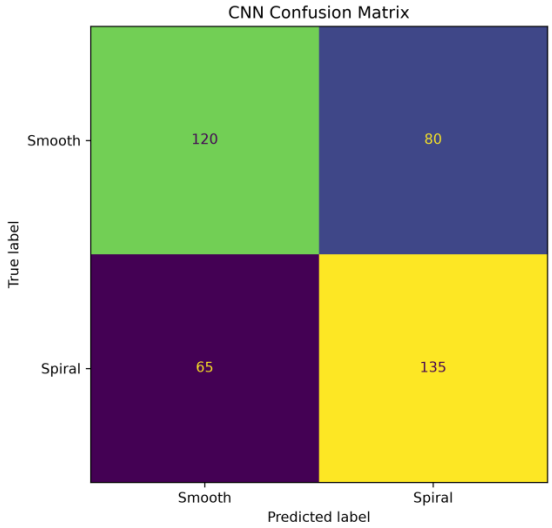
Posmatrajući ukupne rezultate može se zaključiti da složenije arhitekture dubokog učenja ostvaruju bolje performanse od jednostavne konvolucione neuronske mreže. U okviru sprovedenog eksperimenta ResNet18 se pokazao kao najuspešniji model za binarnu klasifikaciju galaksija, ostvarivši najveću tačnost i najbolje vrednosti svih evaluacionih metrika.

Dobijeni rezultati ukazuju da upotreba rezidualnih veza u arhitekturi ResNet18 omogućava efikasnije učenje reprezentacija astronomskih slika u odnosu na klasičnu CNN arhitekturu, dok EfficientNetB0, uprkos primeni transfer learning pristupa, u ovom eksperimentu nije ostvario bolje performanse od ResNet18.

Macro F1-score predstavlja jednu od najznačajnijih metrika u ovom istraživanju, jer izračunava F1-score za svaku klasu pojedinačno, a zatim određuje njihov aritmetički prosek. Na taj način obe klase imaju jednak uticaj na konačnu vrednost metrike, bez obzira na njihov broj u skupu podataka. Iako je u ovom istraživanju korišćen balansiran skup podataka, Macro F1-score pruža pouzdaniju procenu ukupne sposobnosti modela da jednako uspešno klasifikuje i eliptične i spiralne galaksije. Najvišu vrednost ove metrike ostvario je ResNet18 (0,8100), zatim EfficientNetB0 (0,7825), dok je CNN ostvario najnižu vrednost (0,6370).

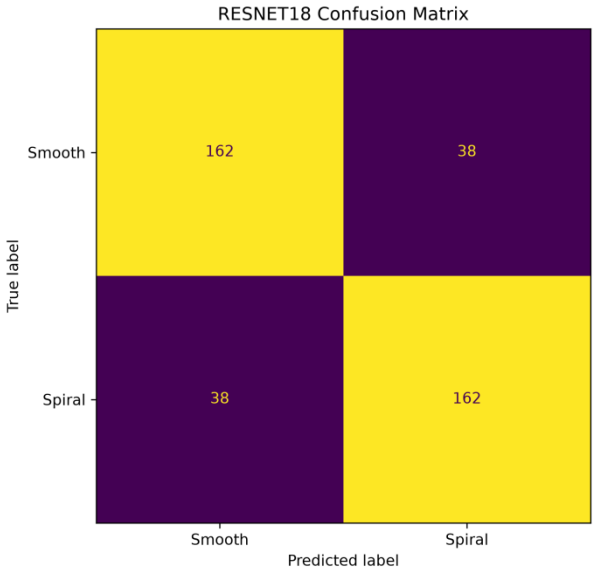
4.3.2 MATRICE KONFUZIJE

Na slici 15. prikazana je matrica konfuzije za CNN model, gde se jasno vidi da je CNN 80 puta rekao da je na slici eliptična galaksija, dok je na slici u stvarnosti bila spiralna, a isto tako vidimo da je 65 puta rekao da je na slici spiralna, dok je u stvarnosti na slici bila eliptična galaksija. Broj puta kada je tačno predvideo šta je na slici za spiralne galaksije je 135, dok je za eliptične tačno predvideo 120 puta.



Slika 15. – Prikaz matrice konfuzije za CNN model.

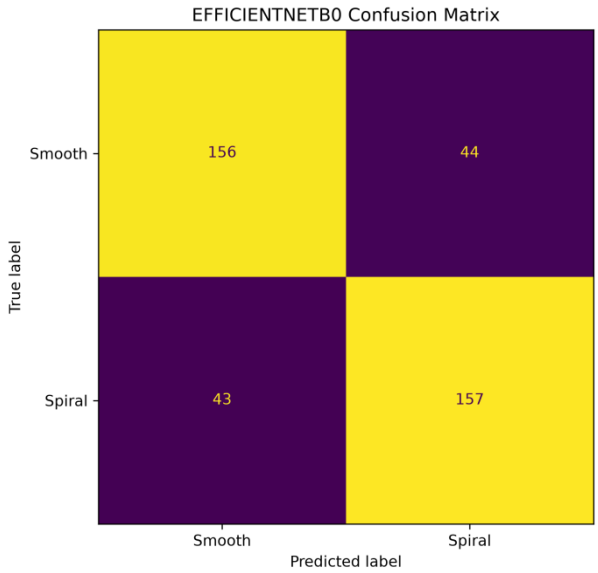
Na slici 16. prikazana je matrica konfuzije za ResNet18 model, gde se vidi da je model u slučaju kada je prikazana spiralana galaksija na slici, rekao da je ustvari prikazana eliptična samo 38 puta, dok je kada je ustvari bila prikazana eliptična, rekao da je spiralna takođe samo 38 puta. U slučajevima kada se predviđanje poklopilo sa klasom slike koja je prikazana je 162 u oba slučaja.



Slika 16. – Prikaz matrice konfuzije za ResNet18 model.

Na slici 17. prikazana je matrica konfuzije za model EfficientNetB0 na kojoj se vidi da je model svojim predviđanjem kada je spiralna galaksija prikazana pogodio 157 puta, a

promašio svega 43 puta. Dok je svojim predviđanjem kada je eliptična galaksija prikazana pogodio 156 a promašio 44 puta.

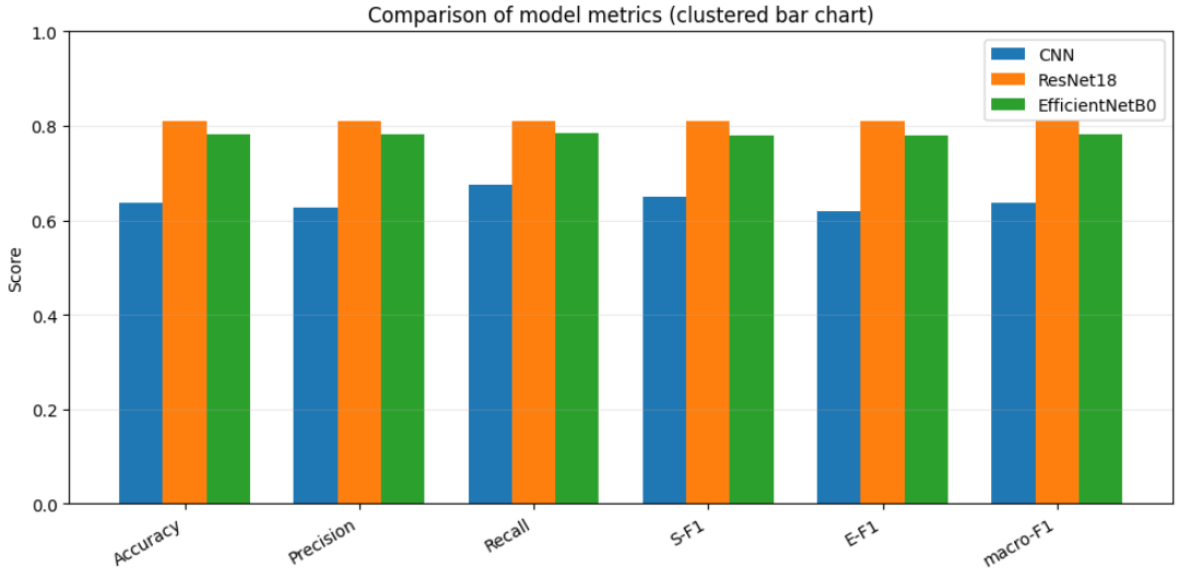


Slika 17. – Prikaz matrice konfuzije za EfficientNetB0 model.

Iz ovoga se takođe može zaključiti da je ResNet18 bolji u klasifikovanju obe vrste galaksija u odnosu na ostale implementirane modele.

4.3.3 UPOREDNA ANALIZA

Uporedna analiza svih metrika za sva tri modela prikazana je na slici 18:



Slika 18. – Prikaz uporedne analize svih metrika za sva tri modela.

4.3.4 ANALIZA POJEDINAČNIH PREDIKCIJA

Slike 19, 20 i 21 prikazuju tri nasumično odabrane galaksije (jedna spiralna, druga takođe spiralna ali ima smetnje na slici i treća eliptična), za koje su sva tri modela izvršili predikciju.



Slike 19, 20 i 21 – Prikaz dve spiralne galaksije i jedne eliptične galaksije nad kojima su modeli vršili predikcije.

Ispis rezultata predikcija sva tri modela za prvi sliku (jasnu spiralnu galaksiju) se nalazi u listingu 1:

Listing 1. – Prikaz ispisa predikcija sva tri modela za prvu sliku (jasnu spiralnu galaksiju).

```
Model      : cnn
Prediction : Smooth (E)
Probability: 0.3665

Model      : resnet18
Prediction : Spiral (S)
Probability: 0.9914

Model      : efficientnetb0
Prediction : Spiral (S)
Probability: 0.7537
```

Na osnovu rezultata možemo videti da CNN nije uradio tačnu predikciju, dok ResNet18 i EfficientNetB0 jesu, s tim da je ResNet18 bio najsigurniji u svoju predikciju.

Ispis rezultata predikcija sva tri modela za drugu sliku (spiralna sa smetnjom na slici) se nalazi u listingu 2:

Listing 2. – Prikaz ispisa predikcija sva tri modela za drugu sliku (spirala sa smetnjom na slici).

```
Model      : cnn
Prediction : Smooth (E)
Probability: 0.0915
```

```
Model      : resnet18
Prediction : Spiral (S)
Probability: 0.5414

Model      : efficientnetb0
Prediction : Spiral (S)
Probability: 0.8482
```

Iz ovih rezultata jasno je da predikcija modela CNN nije tačna iako je sigurnost njegove predikcija bila prilično visoka. Međutim, modeli EfficientNetB0 i ResNet18 jesu pogodili o kojoj galaksiji je reč, ali je ovog puta EfficientNetB0 bio sigurniji u svoju predikciju nego ResNet18.

Ispis rezultata predikcija sva tri modela za treću sliku (eliptična) se nalazi u listingu 3:

Listing 3. – Prikaz ispisa predikcija sva tri modela za treću sliku (eliptična).

```
Model      : cnn
Prediction : Spiral (S)
Probability: 0.5360

Model      : resnet18
Prediction : Smooth (E)
Probability: 0.0276

Model      : efficientnetb0
Prediction : Smooth (E)
Probability: 0.2167
```

ResNet18 je ponovo pogodio sa najvećom sigurnošću, zatim EfficientNetB0 sa malo manjom sigurnošću, ali je CNN promašio svojom predikcijom i time prikazao da iako ima preciznost veću od 60%, da to ipak nije merodavno već da više liči na bacanje novčića.

4.3.5 DISKUSIJA REZULTATA

Na osnovu rezultata dobijenih eksperimentalnim istraživanjem može se zaključiti da je hipoteza postavljena u ovom radu potvrđena. Arhitekture ResNet18 i EfficientNetB0 ostvarile su bolje vrednosti evaluacionih metrika, uključujući i macro-F1, u odnosu na klasičnu CNN arhitekturu pri binarnoj klasifikaciji galaksija nad Galaxy Zoo 2 skupom podataka.

5 KLJUČNI DELOVI KODA

U ovom poglavlju biće prikazani i objašnjeni najznačajniji delovi implementacije razvijenog softverskog rešenja za morfološku klasifikaciju galaksija primenom dubokog učenja. Poseban akcenat stavljen je na pripremu skupa podataka, kreiranje arhitektura modela, proces treniranja i evaluaciju istreniranih modela.

5.1 PRIPREMA SKUPA PODATAKA

Jedan od najvažnijih delova implementacije predstavlja priprema skupa podataka za proces treniranja modela. Nakon učitavanja FITS kataloga i povezivanja sa odgovarajućim JPEG slikama galaksija, zadržane su samo galaksije koje pripadaju klasama E (engl. Smooth) i S (engl. Spiral). Dobijeni skup podataka sadrži putanju do slike i odgovarajuću oznaku klase, čime je pripremljen ulaz za dalji proces treniranja modela.

Listing 4. – Prikaz dela koda koji je ključan za pripremu skupa podataka.

```
df_es = df_dataset[
    df_dataset["class4"].isin(["E", "S"])
].copy()
df_es = df_es[
    [
        "image_path",
        "class4"
    ]
]
df_es = df_es.rename(
    columns={
        "class4": "label"
    }
)
```

5.2 KREIRANJE TENSORFLOW SKUPA PODATAKA

Nakon pripreme skupa podataka, izvršeno je njegovo prilagođavanje za korišćenje u okviru TensorFlow biblioteke implementacijom funkcije create_tf_dataset(). Ova funkcija od putanja do slika i njihovih oznaka formira TensorFlow skup podataka (tf.data.Dataset), koji se koristi tokom treniranja, validacije i evaluacije modela.

Prilikom učitavanja svaka slika se dekodira iz JPG formata, menja joj se rezolucija na 224 × 224 piksela i vrši se normalizacija vrednosti piksela. Za modele CNN i ResNet18 primenjuje se standardna normalizacija u opseg [0,1], dok se za EfficientNetB0 koristi funkcija preprocess_input(), prilagođena ovoj arhitekturi.

Listing 5. – Prikaz ključnog dela koda za kreiranje tensorflow dataset-a.

```
def create_tf_dataset(
    dataframe,
    image_size,
    batch_size,
    model_name,
    shuffle=False
):

    dataset = tf.data.Dataset.from_tensor_slices(
        (
            dataframe["image_path"].values,
            dataframe["label"].values
        )
    )

    dataset = dataset.map(
        lambda path, label: load_image(
            path,
            label,
            image_size,
            model_name
        ),
        num_parallel_calls=tf.data.AUTOTUNE
    )

    if shuffle:
        dataset = dataset.shuffle(buffer_size=len(dataframe), seed=42,
reshuffle_each_iteration=False)

    dataset = dataset.batch(batch_size)
```

```
    dataset = dataset.prefetch(tf.data.AUTOTUNE)


    return dataset
```

Radi efikasnijeg treniranja, podaci se po potrebi nasumično mešaju (eng. shuffle), grupišu u pakete unapred definisane veličine (eng. batch) i unapred učitavaju (eng. prefetch), čime se ubrzava obrada podataka i poboljšava iskorišćenost računarskih resursa.

5.3 IMPLEMENTACIJA MODELA DUBOKOG UČENJA

U daljem tekstu biće prikazana implementacija tri različita modela dubokog učenja.

5.3.1 KONVOLUCIONA NEURONSKA MREŽA (CNN)

CNN model sastoji se od tri konvoluciona bloka koji služe za ekstrakciju karakteristika slike. Nakon njih sledi Global Average Pooling sloj i potpuno povezani sloj koji vrši binarnu klasifikaciju galaksija.

Listing 6. – Prikazuje funkciju za kreiranje CNN modela.

```
tf.keras.layers.Input(shape=INPUT_SHAPE),


        # Block 1

        tf.keras.layers.Conv2D(filters=32, kernel_size=(3, 3), padding="same", activation="relu",
kernel_initializer="he_normal"), #kernel_regularizer=tf.keras.regularizers.l2(1e-4)

        tf.keras.layers.ReLU(),

        tf.keras.layers.MaxPooling2D(pool_size=(2, 2)),


        # Block 2

        tf.keras.layers.Conv2D(filters=64, kernel_size=(3, 3), padding="same", activation="relu",
kernel_initializer="he_normal"), #, kernel_regularizer=tf.keras.regularizers.l2(1e-4)

        tf.keras.layers.ReLU(),

        tf.keras.layers.MaxPooling2D(pool_size=(2, 2)),


        # Block 3

        tf.keras.layers.Conv2D(filters=128, kernel_size=(3, 3), padding="same", activation="relu",
kernel_initializer="he_normal"), #, kernel_regularizer=tf.keras.regularizers.l2(1e-4)

        tf.keras.layers.ReLU(),

        tf.keras.layers.MaxPooling2D(pool_size=(2, 2)),
```

```
    # Classification head
    tf.keras.layers.GlobalAveragePooling2D(),

    tf.keras.layers.Dense(units=128, activation="relu", kernel_initializer="he_normal"), #,
kernel_regularizer=tf.keras.regularizers.l2(1e-4)
    tf.keras.layers.Dropout(rate=0.2),

    tf.keras.layers.Dense(units=1, activation="sigmoid")
```

5.3.2 RESNET18

Jedan od ključnih delova implementacije ResNet18 modela jeste funkcija residual_block(), koja predstavlja osnovni gradivni element ove arhitekture. Za razliku od klasičnih konvolucionih neuronskih mreža, ResNet koristi rezidualne veze (engl. residual connections), koje omogućavaju da se ulaz u blok direktno prosledi njegovom izlazu.

Listing 7. prikazuje funkciju residual_block():

Listing 7. – Prikazuje funkciju residual_block().

```
def residual_block(x, filters, stride=1):
  shortcut = x
  # First conv
  x = tf.keras.layers.Conv2D(
    filters,
    kernel_size=3,
    strides=stride,
    padding="same",
    use_bias=False,
    kernel_initializer="he_normal",
    kernel_regularizer=tf.keras.regularizers.l2(1e-4)
  )(x)
  x = tf.keras.layers.BatchNormalization()(x)
  x = tf.keras.layers.ReLU()(x)

  # Second conv
  x = tf.keras.layers.Conv2D(
```

```
        filters,
        kernel_size=3,
        strides=1,
        padding="same",
        use_bias=False,
        kernel_initializer="he_normal",
        kernel_regularizer=tf.keras.regularizers.l2(1e-4)
    )(x)

    x = tf.keras.layers.BatchNormalization()(x)

    # Projection shortcut
    if stride != 1 or shortcut.shape[-1] != filters:

        shortcut = tf.keras.layers.Conv2D(
            filters,
            kernel_size=1,
            strides=stride,
            padding="same",
            use_bias=False,
            kernel_initializer="he_normal",
            kernel_regularizer=tf.keras.regularizers.l2(1e-4)
        )(shortcut)

        shortcut = tf.keras.layers.BatchNormalization()(shortcut)

    # Residual connection
    x = tf.keras.layers.Add()([x, shortcut])
    x = tf.keras.layers.ReLU()(x)
    return x
```

Rezidualna veza ostvaruje se sabiranjem izlaza konvolucionih slojeva sa originalnim ulazom bloka. Ovakav pristup omogućava lakše propagiranje gradijenata kroz duboke mreže, čime se ublažava problem nestajanja gradijenta (engl. vanishing gradient) i omogućava uspešnije treniranje modela sa većim brojem slojeva. Zahvaljujući tome,

ResNet18 postiže bolje performanse i stabilnije učenje u odnosu na klasične CNN arhitekture.

5.3.3 EFFICIENTNETB0

Za implementaciju EfficientNetB0 modela korišćen je pristup transfernog učenja (engl. Transfer Learning), pri čemu je iskorišćena unapred istrenirana arhitektura dostupna u okviru TensorFlow biblioteke.

Model je inicijalizovan sa težinama naučenim na skupu podataka ImageNet, dok je njegov originalni klasifikacioni deo uklonjen postavljanjem parametra "include_top=False".

Prikaz koda za inicijalizaciju EfficientNetB0 modela se može videti u listingu 8:

Listing 8. – Prikaz koda za inicijalizaciju modela EfficientNetB0.

```
base_model = EfficientNetB0(weights="imagenet", include_top=False)
```

Kako bi se sačuvale prethodno naučene karakteristike modela, svi slojevi osnovne mreže su u početnoj fazi treniranja zamrznuti postavljanjem svojstva "trainable" na vrednost "False".

U listingu 9. prikazuje se zamrzavanje osnovnog modela:

Listing 9. – Prikaz koda za zamrzavanje osnovnog modela EfficientNetB0.

```
base_model.trainable = False
```

5.4 PROCES TRENIRANJA MODELA

Proces treniranja svih modela realizovan je korišćenjem funkcije model.fit(), kojoj se prosleđuju skup podataka za treniranje, validacioni skup, broj epoha i odgovarajući callback mehanizmi za kontrolu procesa treniranja.

Listing 10. – Prikaz poziva funkcije za treniranje modela.

```
history = model.fit(
    train_ds,
    validation_data=val_ds,
    epochs=epochs,
    callbacks=[
        ...
    ]
)
```

Tokom treniranja korišćena su tri callback mehanizma koja omogućavaju efikasnije i stabilnije učenje modela.

EarlyStopping prati vrednost tačnosti na validacionom skupu (val_accuracy) i automatski prekida treniranje ukoliko tokom definisanog broja epoha ne dođe do poboljšanja rezultata. Na ovaj način sprečava se pretreniranje modela i smanjuje nepotrebno vreme treniranja.

ReduceLROnPlateau automatski smanjuje stopu učenja (learning rate) kada se primeti da validaciona tačnost prestaje da raste. Smanjenjem stope učenja model dobija mogućnost da preciznije pronađe optimalne vrednosti parametara i ostvari bolje performanse.

ModelCheckpoint čuva verziju modela koja postiže najbolju vrednost validacione tačnosti tokom treniranja. Zahvaljujući tome, za kasniju evaluaciju i predikciju koristi se najbolji model, bez obzira na rezultate poslednje epohe.

Kombinacijom ovih callback mehanizama ostvaruje se stabilniji proces treniranja, smanjuje mogućnost pretreniranja i obezbeđuje čuvanje modela sa najboljim postignutim performansama.

5.5 EVALUACIJA MODELA DUBOKOG UČENJA

Nakon završetka procesa treniranja izvršena je evaluacija modela nad test skupom podataka. Cilj evaluacije bio je da se objektivno proceni sposobnost modela da generalizuje na neviđene podatke, kao i da se uporede performanse različitih arhitektura.

Evaluacija je sprovedena korišćenjem standardnih metrika iz biblioteke scikit-learn, uključujući: Accuracy, Precision, Recall i F1-score, dok je dodatno izračunata i vrednost macro-F1 metrike, koja daje balansiran pregled performansi modela nezavisno od raspodele klasa.

Listing 11. prikazuje kod za proračun gore navedenih metrika:

Listing 11. – Prikaz proračuna metrika Accuracy, Precision, Recall i F1-score, kao i dodatnu macro-F1 metriku.

```
accuracy = accuracy_score(true, preds)

precision = precision_score(true, preds, zero_division=0)

recall = recall_score(true,preds,zero_division=0)

f1 = f1_score(true,preds,zero_division=0)

macro_f1 = f1_score(true,preds,average="macro",zero_division=0)
```

6 ZAKLJUČAK

U okviru ovog master rada sprovedena je komparativna analiza performansi različitih arhitektura dubokog učenja u zadatku binarne klasifikacije morfoloških tipova galaksija na osnovu Galaxy Zoo 2 skupa podataka. Istraživanje je bilo usmereno na poređenje klasične konvolucione neuronske mreže (CNN), ResNet18 i EfficientNetB0 modela, uz identične uslove treniranja i evaluacije, kako bi se obezbedila objektivna analiza njihovih performansi.

Na osnovu sprovedenih eksperimenata, prodiskutovanih rezultata u okviru analize rezultata, potvrđena je postavljena hipoteza da izbor arhitekture neuronske mreže ima značajan uticaj na tačnost i kvalitet klasifikacije galaksija, a takođe je dokazano da savremenije arhitekture dubokog učenja (ResNet18 i EfficientNetB0) ostvaruju bolje performanse u odnosu na jednostavnije modele poput klasičnog CNN-a, kako u pogledu tačnosti, tako i u pogledu stabilnosti i sposobnosti generalizacije.

Rezultati su pokazali da klasična CNN arhitektura, iako funkcionalna, ostvaruje slabije performanse u poređenju sa dubljim i optimizovanim modelima. ResNet18 je pokazao značajno poboljšanje zahvaljujući rezidualnim vezama koje omogućavaju efikasnije učenje, dok je EfficientNetB0 ostvario najbolje ukupne rezultate, potvrđujući efikasnost principa balansiranog skaliranja dubine, širine i rezolucije mreže.

Na osnovu navedenog može se zaključiti da je hipoteza istraživanja u potpunosti potvrđena, jer su eksperimentalni rezultati jasno pokazali da arhitektura dubokog učenja direktno utiče na performanse modela u zadatku klasifikacije galaksija.

Ograničenja ovog istraživanja odnose se na veličinu i distribuciju skupa podataka, kao i na izbor hiperparametara. Buduća istraživanja mogu biti usmerena ka primeni naprednijih arhitektura, optimizaciji trening procesa i korišćenju većih i raznovrsnijih skupova podataka.

7 LITERATURA I ILUSTRACIJE

Literatura:

[1] Definicija Veštačke inteligencije, „What is artificial intelligence (AI)?“, IBM, URL: https://www.ibm.com/think/topics/artificial-intelligence

[2] Grane veštačke inteligencije, „Top 10 branches of Artificial Intelligence”, Geeks for Geeks, URL: https://www.geeksforgeeks.org/artificial-intelligence/top-10-branches-of-artificial-intelligence/

[3] Definicija analize sentimenata, „What is sentiment analysis?”, Elastic, URL: https://www.elastic.co/what-is/sentiment-analysis

[4] Definicija chatbot-a, „What is a Chatbot?”, The Stanford Institute for Human-Centered AI (HAI), URL: https://hai.stanford.edu/ai-definitions/what-is-a-chatbot

[5] Definicija AI agenta, „What Are AI Agents?”, Oracle, URL: https://www.oracle.com/artificial-intelligence/ai-agents/

[6] Definicija mašinskog učenja, o mašinskom učenju i njegovi tipovi, „What is Machine Learning?“, Oracle, URL: https://www.oracle.com/apac/artificial-intelligence/machine-learning/what-is-machine-learning/

[7] Način rada mašinskog učenja, „Machine learning (ML): All there is to know”, International Organization for Standardization (ISO), URL: https://www.iso.org/artificial-intelligence/machine-learning

[8] Definicija dubokog učenja, „What is deep learning?”, IBM, URL: https://www.ibm.com/think/topics/deep-learning

[9] Način rada dubokih mreža, „What Is Deep Learning and How Does It Work?“, builtin, URL: https://builtin.com/machine-learning/deep-learning

[10] Snaga dubokog učenja, „What is Image Recognition? Technology, Applications, and Benefits“, imagga, URL: https://imagga.com/blog/what-is-image-recognition-technology-applications-and-benefits/

[11] Uloga GPU u dubokom učenju, „Why Deep Learning Need GPU”, Geeks for Geeks, URL: https://www.geeksforgeeks.org/deep-learning/why-deep-learning-need-gpu/

[12] Definicija neuronskih mreža, „What is a neural network?“, IBM, URL: https://www.ibm.com/think/topics/neural-networks

[13] Definicija neurona, „ Introduction to Neurons in Neural Networks“, Medium, URL: https://medium.com/artificial-neural-networks/introduction-to-neurons-in-neural-networks-71828d040a65

[14] Definicija težine i bias vrednosti, „Weights and Bias in Neural Networks “, Geeks for Geeks, URL: https://www.geeksforgeeks.org/deep-learning/the-role-of-weights-and-bias-in-neural-networks/

[15] Definicija aktivacione funkcije, „Activation Functions in Neural Networks “, Geeks for Geeks, URL: https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-networks/
[16] Definicija feedforward neuronske mreže, „Feedforward Neural Network“, Geeks for Geeks, URL: https://www.geeksforgeeks.org/deep-learning/feedforward-neural-network/
[17] Definicija CNN, „Introduction to Convolution Neural Network “, Geeks for Geeks, URL: https://www.geeksforgeeks.org/machine-learning/introduction-convolution-neural-network/
[18] Definicija ResNet18, „ResNet18 from Scratch Using PyTorch “, Geeks for Geeks, URL: https://www.geeksforgeeks.org/deep-learning/resnet18-from-scratch-using-pytorch/
[19] Prednosti i nedostaci ResNet18, „ResNet-18“, Aicuflow, URL: https://www.aicuflow.com/docs/tool/training/computer_vision/image_classification/resnet-18
[20] Definicija EfficientNetB0, „EfficientNetB0 architecture – Stem Layer“, Medium, URL: https://medium.com/image-processing-with-python/efficientnetb0-architecture-stem-layer-496c7911a62d
[21] Prednosti i nedostaci EfficientNetB0, „What is EfficientNet? A quick overview“, Ultralytics, URL: https://www.ultralytics.com/blog/what-is-efficientnet-a-quick-overview#pros-and-cons-of-efficientnet\
[22] Definicija evaluacione metrike i metrike za klasifikaciju , „Evaluation Metrics in Machine Learning“, Geeks for Geeks, URL: https://www.geeksforgeeks.org/machine-learning/metrics-for-machine-learning-model/
[23] Definicija Macro F1 evaluacione metrike, „Macro F1 score evaluation metric“, IBM, URL: https://www.ibm.com/docs/en/watsonx/saas?topic=metrics-macro-f1-score
[24] Definicija Galaxy Zoo, „Galaxy Zoo “, NASA, URL: https://science.nasa.gov/citizen-science/galaxy-zoo/
[25] Definicija Galaxy Zoo 2 i način glasanja „Galaxy Zoo 2: detailed morphological classifications for 304,122 galaxies from the Sloan Digital Sky Survey“, arXiv, URL: https://arxiv.org/abs/1308.3496
[26] Morfološka klasifikacija galaksija, “Morphological Classification of Galaxies”, ResearchGate, URL: https://www.researchgate.net/publication/388963255_Morphological_Classification_of_Galaxies
[27] Visual Studio Code, “Get started with Visual Studio Code”, Microsoft, URL: https://code.visualstudio.com/docs/getstarted/overview
[28] Galaxy Zoo 2 projekat, “”, Galaxy Zoo, URL:

https://arxiv.org/abs/1308.3496
[29] SDSS, “Sloan Digital Sky Survey”,Sloan Digital Sky Survey, URL: https://sloan.org/programs/research/sloan-digital-sky-survey
[30] arXiv distributivni servis, “arXiv”, arXiv, URL: https://arxiv.org/
[31] Galaxy Zoo projekat, .fits fajl, “Galaxy Zoo 2”, Galaxy Zoo, URL: https://data.galaxyzoo.org/#section-7

Ilustracije:

Broj slike	Naziv	Izvor
1	*Prikaz ilustracije skupa veštačke inteligencije sa podskupovima*	https://builtin.com/machine-learning/deep-learning
2	*Prikaz ilustracije arhitekture feedforward neuronske mreže*	https://www.akamai.com/glossary/what-is-a-neural-network
3	*Prikaz linearne aktivacione funkcije*	https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-networks/
4	*Prikaz Sigmoidne aktivacione funkcije*	https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-networks/
5	*Prikaz Tanh aktivacione funkcije*	https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-networks/
6	*Prikaz ReLU aktivacione funkcije*	https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-networks/
7	*Prikaz Leaky ReLU aktivacione funkcije*	https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-networks/
8	*Prikaz softplus aktivacione funkcije*	https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-networks/
9	*Prikaz ELU funkcije*	https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-networks/
10	*Prikaz SELU funkcije*	https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-networks/
11	*Prikaz sigmoidne aktivacione*	https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-

	funkcije	networks/
12	*Prikaz Softmax aktivacione funkcije*	https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-networks/
13	*Prikaz organizacije direktorijuma i poddirektorijuma unutar projekta*	Slika ekrana sa otvorenim okruženjem Visual Studio Code.
14	*Prikaz izgleda skupa podataka „dataset_ES.csv”.*	Slika ekrana sa otvorenom .csv tabelom “dataset_ES.csv”.
15	*Prikaz matrice konfuzije za CNN model*	Slika generisana evaluacijom iz projekta u Visual Studio Code-u.
16	*Prikaz matrice konfuzije za ResNet18 model*	Slika generisana evaluacijom iz projekta u Visual Studio Code-u.
17	*Prikaz matrice konfuzije za EfficientNetB0 model*	Slika generisana evaluacijom iz projekta u Visual Studio Code-u.
18	*Prikaz uporedne analize svih metrika za sva tri modela*	Slika ekrana sa otvorenom platformom Google Colab pri plotovanju metrika sva tri modela
19	*Prikaz dve spiralne galaksije i jedne eliptične galaksije nad kojima su modeli vršili predikcije*	Slika je ubačena iz Galaxy Zoo 2 skupa podataka
20	*Prikaz dve spiralne galaksije i jedne eliptične galaksije nad kojima su modeli vršili predikcije*	Slika je ubačena iz Galaxy Zoo 2 skupa podataka
21	*Prikaz dve spiralne galaksije i jedne eliptične galaksije nad kojima su modeli vršili predikcije*	Slika je ubačena iz Galaxy Zoo 2 skupa podataka